

## 个人角色与工作内容

我担任小组组长，全面统筹项目、制定研究方案、确定分析内容与技术路线，并负责关键决策工作。

主要工作：

1. 整体项目规划、进度把控、分工安排与最终质量审核。
2. 数据来源查找、数据集筛选、确定分析内容与研究目标。
3. 确定研究框架、技术路线与模型选型决策。
4. 协调成员工作、解决问题、整合报告与答辩。

# 基于机器学习模型的台湾高雄市空气质量

## 时空演变分析与可解释性研究

### 目 录

|                           |    |
|---------------------------|----|
| 一、前言 .....                | 1  |
| 1.1 项目背景 .....            | 1  |
| 1.1.1 研究背景 .....          | 1  |
| 1.1.2 研究意义 .....          | 1  |
| 1.2 文献综述 .....            | 2  |
| 二、数据处理 .....              | 3  |
| 2.1 数据描述 .....            | 3  |
| 2.2 数据预处理 .....           | 5  |
| 2.3 探索性数据分析 .....         | 11 |
| 2.3.1 单变量分析 .....         | 11 |
| 2.3.2 多变量分析 .....         | 16 |
| 2.3.3 聚类分析 .....          | 18 |
| 三、特征工程 .....              | 20 |
| 3.1 时间特征工程 .....          | 21 |
| 3.2 风场特征工程 .....          | 21 |
| 3.3 滞后特征 .....            | 22 |
| 3.4 滚动统计量 .....           | 23 |
| 3.5 邻居站点聚合特征 .....        | 24 |
| 四、模型建立与应用 .....           | 25 |
| 4.1 ARIMA 模型 .....        | 25 |
| 4.2 随机森林模型 .....          | 29 |
| 4.3 Light GBM 模型 .....    | 33 |
| 4.4 LSTM 模型 .....         | 38 |
| 4.5 Transformer 模型 .....  | 43 |
| 4.6 模型评估 .....            | 47 |
| 4.7 模型选择与模型改进 .....       | 48 |
| 五、建模结果解释 .....            | 51 |
| 5.1 Xiaogang 建模结构解释 ..... | 51 |
| 5.2 linyuan 建模结构解释 .....  | 54 |
| 5.3 Qianjin 建模结构解释 .....  | 56 |
| 5.4 Zuoying 建模结构解释 .....  | 58 |
| 5.5 Meinong 建模结构解释 .....  | 60 |
| 六、结论与展望 .....             | 62 |
| 6.1 结论 .....              | 62 |
| 6.2 展望 .....              | 63 |
| 七、参考文献 .....              | 63 |

## 一、前言

### 1.1 项目背景

#### 1.1.1 研究背景

空气污染是当今全球最严重的公共卫生威胁之一。细颗粒物（PM<sub>2.5</sub>）因其可深入肺泡并进入血液循环，已被确认为心血管疾病、呼吸系统疾病、肺癌及中风等的主要环境风险因子。台湾南部的高雄市，作为重工业（石化、钢铁、火力发电）密集区，叠加港口货运与冬季东北季风带来的境外污染物跨境输送，其 PM<sub>2.5</sub> 年均浓度常年维持在 20-35 $\mu\text{g}/\text{m}^3$  之间，远超世界卫生组织（WHO）的最新建议值（5 $\mu\text{g}/\text{m}^3$ ），长期位列全台空气质量最差区域，对公众健康构成重大威胁。

2020 年初新冠疫情的爆发为空气质量变化提供了一次罕见的自然实验。台湾实施的严格管制措施曾导致交通与工业排放急剧下降，促使高雄市 2020 年 PM<sub>2.5</sub> 浓度创下近年新低。然而，随着防疫限制的解除和经济活动的快速重启，叠加季节性外源传输，PM<sub>2.5</sub> 浓度呈现剧烈的“V 型反弹”。在 2022-2024 年的冬季，重度污染事件频发，污染水平在短时间内从历史低谷快速回到甚至超过疫情前状态，形成了典型的“异常低值-快速反弹-高值频发”非平稳序列。

本研究聚焦于台湾省高雄市。高雄市作为重要的工业和港口枢纽，其 PM<sub>2.5</sub> 年均浓度长期位居全台最高，重污染事件频繁，直接触发了如学校停课、限制老人儿童户外活动、工地与港口限排等严苛的应急措施。现有的业务预警系统在近年来空气质量剧烈波动的背景下（特别是 2020 年新冠疫情后），多次出现显著的漏报或误报。这导致健康防护提示与工业、交通限制作业启动滞后，公众暴露风险与社会经济成本均明显增加。因此，升级预警系统、确保其在非平稳背景下的预测可靠性成为高雄市环保工作的当务之急。

#### 1.1.2 研究意义

本研究以高雄市 2020-2024 年空气质量数据为具体案例，旨在：

（1）构建并评估多种机器学习模型（MLR、SVR、RF、GB 等），确定在涵盖疫情影响的非平稳周期内表现最稳定、预测精度最高的算法。

（2）筛选出在极端重污染事件预测中，能有效避免漏报或误报、满足业务预警系统需求的预测方案。

（3）通过模型解释性分析，识别出在非平稳背景下，对高雄市 PM<sub>2.5</sub>PM<sub>10</sub> 预测起关键作用的物理预测因子清单。

尽管研究对象是高雄市，但本研究得出的关于不同算法在非平稳周期中的真实表现排序、对关键预测因子的物理意义解释，以及对模型失效模式的归因分析，具有高度的普适性。同时，

对于全球其他面临类似突发性社会经济/环境冲击（如：国际体育赛事、自然灾害、全球性公共卫生事件）的城市，本研究可提供经验借鉴，指导其在类似冲击情景下快速构建或调整鲁棒预警系统，以更有效地应对未来空气质量的突变风险。

## 1.2 文献综述

近年来，机器学习在空气质量预测与溯源领域的应用研究快速发展，已成为数据驱动环境治理的核心工具。

裴飞扬等、Karmoude 等、Iqbal 和 Mukherjee 综述一致认为，集成学习（随机森林、XGBoost、LightGBM、CatBoost）在结构化日尺度数据上长期保持最高精度与最强鲁棒性，而深度学习（LSTM、CNN、Bi-LSTM）虽在捕捉长时依赖与时空模式方面具有明显优势，但在真实分布剧烈偏移场景下的泛化能力仍有待更多实证检验。<sup>[1,9,10]</sup>

区域实证研究进一步强化了集成学习的领先地位。魏佳芳等在绵阳、秦杨等在吉林白城、朱效锋等在广州分别独立验证：XGBoost 与随机森林显著优于支持向量机、决策树与浅层神经网络，测试集  $R^2$  普遍介于 0.92-0.9965；SHAP 分析共同显示  $PM_{2.5}$ 、 $PM_{10}$  与  $O_3$  为首要驱动因子，高污染期污染物协同效应显著增强。金长宇等虽研究矿山爆堆大块率，但通过两轮调优使 CatBoost 达到  $R^2=98.83\%$ ，同样印证了集成学习在小样本、强噪声环境下的极强鲁棒性。吕红燕和冯倩、杨剑锋等从算法原理层面较早阐明了随机森林与集成学习不易过拟合、对异常值容忍度高的理论基础，与近年实证结论高度吻合。<sup>[2-7]</sup>

可解释性已成为当前研究的标配需求。Muralikrishnan 等采用 SHAP 量化各因子贡献，使模型不仅“能预测”，更“能解释”，为分时段、差异化精准防控提供了科学依据。Muhammad 等提出的 Fermatean 模糊 Spearman 秩相关框架与 Amjad 等在路面状况预测中对 Spearman 系数的应用，则为污染物权重排序与模型诊断提供了新的方法论参考。<sup>[11-13]</sup>

在健康风险与治理需求层面，涂佩玥等基于 2015-2020 年中国 168 个重点城市数据发现，京津冀、汾渭平原及台湾南部同属健康风险最高梯队， $O_3$  正逐步取代  $PM_{2.5}$  成为主导污染物；He 等 Meta 分析纳入超 4300 万人队列，进一步证实  $PM_{2.5}$ 、 $NO_x$ 、 $PM_{10}$  长期暴露显著增加非酒精性脂肪肝及肝硬化患病率。这些研究共同表明，高精度、可解释的预测模型已不仅是环境管理工具，更是直接降低公众健康负担、支撑精准治理的公共卫生必需品。<sup>[8,14]</sup>

综上所述，现有研究已形成较为一致的认识：集成学习尤其是 XGBoost 与随机森林，目前仍是日尺度颗粒物与 AQI 预测中精度最高、鲁棒性最强、最易结合 SHAP 实现可解释的算法家族；深度学习虽具潜力，但对疫情后这类剧烈非平稳场景的适应性尚需更多实证支撑。正

是在这一背景下，本研究选取高雄市 2020-2024 年这一覆盖疫情骤降与后疫情重污染反复的完整非平稳周期，系统比较多种主流算法在真实分布偏移情景下的相对表现，以期为台湾南部及东亚同类型复合污染城市提供一份区域性但具有一定参考价值的实证补充。

## 二、数据处理

### 2.1 数据描述

本文数据为台湾空气质量指数数据，数据源自 Kaagle 数据集<sup>1</sup>。原始数据集收集了台湾省 2016 年 1 月 1 日至 2024 年 8 月 31 日的小时数据，其中包括台湾省的个县市，原始数据量为 588 万 2208 条。考虑到数据过于庞大，故从中选取一个有代表性的城市高雄市 (Kaohsiung City) 进行研究。高雄市是台湾空气质量研究中最复杂、最典型、变量最丰富的样本，选择 2020-2024 年这 5 年的时间跨度，得到的数据总量为 56 万 2158 条。高雄市有 19 个监测站点用于监测污染物指标，具体如下表 1 所示：

表 1 各监测站点数据量统计

| 监测站点名称 (sitename)            | 数量    |
|------------------------------|-------|
| Qiaotou                      | 44843 |
| Meinong                      | 44838 |
| Renwu                        | 44838 |
| Xiaogang                     | 44834 |
| Fuxing                       | 44830 |
| Daliao                       | 44826 |
| Linyuan                      | 44824 |
| Qianzhen                     | 44823 |
| Zuoying                      | 44815 |
| Qianjin                      | 44660 |
| Nanzi                        | 43765 |
| Fengshan                     | 40189 |
| Kaohsiung (Hunei)            | 25680 |
| Kaohsiung (Nanzi)            | 2013  |
| Kaohsiung (Zuoying)          | 1330  |
| Kaohsiung (Alian)            | 670   |
| Hunei                        | 220   |
| Nanzi Export Processing Zone | 159   |
| Kaohsiung (Linyuan)          | 1     |

由上表 1 可知非常有必要删除数量少的数据,这些通常是移动监测车、临时站点，或者是数据上传时的命名错误。最后挑选出 5 个地理位置和污染类型不同的站点，即 Xiaogang (小港)、

<sup>1</sup> <https://www.kaggle.com/datasets/taweilo/taiwan-air-quality-data-20162024>

Linyuan (林园)、Qianjin (前金)、Zuoying (左营)和 Meinong (美浓)。最终得到的数据总量为 22 万 3971 条。如下表 2 展示了数据中个指标的含义：

表 2 指标含义

| 指标                     | 中文释义                                                         |
|------------------------|--------------------------------------------------------------|
| date                   | 日期                                                           |
| sitename               | 监测站点名称                                                       |
| AQI                    | 空气质量指数                                                       |
| pollutant              | 首要污染物                                                        |
| status                 | 空气质量状态（等级）                                                   |
| SO <sub>2</sub>        | 二氧化硫浓度（ $\mu\text{g}/\text{m}^3$ ）                           |
| CO                     | 一氧化碳浓度（ $\text{mg}/\text{m}^3$ ）                             |
| O <sub>3</sub>         | 臭氧（1 小时平均）浓度（ $\mu\text{g}/\text{m}^3$ ）                     |
| O <sub>3</sub> _8hr    | 臭氧（8 小时滑动平均）浓度（ $\mu\text{g}/\text{m}^3$ ）                   |
| PM <sub>10</sub>       | 可吸入颗粒物（ $\leq 10\mu\text{m}$ ）浓度（ $\mu\text{g}/\text{m}^3$ ） |
| PM <sub>2.5</sub>      | 细颗粒物（ $\leq 2.5\mu\text{m}$ ）浓度（ $\mu\text{g}/\text{m}^3$ ）  |
| NO <sub>2</sub>        | 二氧化氮浓度（ $\mu\text{g}/\text{m}^3$ ）                           |
| NO <sub>x</sub>        | 氮氧化物（NO+NO <sub>2</sub> ）浓度（ $\mu\text{g}/\text{m}^3$ ）      |
| NO                     | 一氧化氮浓度（ $\mu\text{g}/\text{m}^3$ ）                           |
| windspeed              | 风速（m/s）                                                      |
| winddirec              | 风向（°）                                                        |
| CO_8hr                 | 一氧化碳（8 小时滑动平均）浓度（ $\text{mg}/\text{m}^3$ ）                   |
| PM <sub>2.5</sub> _avg | 细颗粒物平均浓度（ $\mu\text{g}/\text{m}^3$ ）                         |
| PM <sub>10</sub> _avg  | 可吸入颗粒物平均浓度（ $\mu\text{g}/\text{m}^3$ ）                       |
| SO <sub>2</sub> _avg   | 二氧化硫平均浓度（ $\mu\text{g}/\text{m}^3$ ）                         |
| longitude              | 经度（°）                                                        |
| latitude               | 纬度（°）                                                        |
| siteid                 | 监测站点编号                                                       |

图 1 展示了本研究的高雄市空气质量监测站点分布。五个具有代表性的监测站点分别位于不同的地理区域和污染类型代表地。这些站点包括：位于高雄市重工业区的 Xiaogang 站（小港，钢铁/造船业），代表了高雄市的污染核心；Linyuan 站（林园），位于石化工业区，位于高雄市最南端，特征鲜明；Qianjin 站（前金），位于市中心，是交通污染的典型代表；Zuoying 站（左营），为新兴的居住商业区，反映了混合型污染源的情况；以及 Meinong 站（美浓），位于农村/山区，用于评估地形及传输效应对空气质量的影响。




图 1 中国台湾高雄市空气质量监测站点分布

## 2.2 数据预处理

在空气质量研究中，特别是涉及机器学习和深度学习模型的应用中，数据预处理是衔接原始数据和高精度模型的关键桥梁。原始环境监测数据往往具有重复值、缺失值、异常值以及时间序列特性复杂等固有缺陷。这些问题若不加以处理，将直接导致模型训练过程不稳定、收敛速度慢，甚至产生有偏的、不可信的预测结果，从而严重影响研究的可靠性和决策的有效性。

首先，进行重复值的处理，去重的原则是同一站点的同一时间应该只有一条记录，经筛选发现重复记录数达到 21346 条，对多余出的数据进行去除，最后得到 20 万 2625 条数据。

其次，是对缺失值的处理，数据选取的时间尺度是从 2020 年 1 月 1 日至 2025 年 8 月 31 日的小时数据，则一个监测站点就应该拥有 40920 条数据，5 个监测站点合计 20 万 4601 条数据。故需将表格中每个监测站点空缺的时间点进行补充，再综合计算每个站点每个指标的缺失值数量。如下图 2 所示，缺失最多的三个站点为 Linyuan、Qianjin 和 Zuoying。




图 2 各监测站点缺失数据占比

具体地，如下图 3 显示了各站点各变量的数值型数据缺失情况，可以观察到  $\text{SO}_2$ 、 $\text{PM}_{10}$ 、 $\text{NO}_2$ 、 $\text{NO}$  和  $\text{NO}_x$  的缺失情况较为严重，仍在可处理范围内，缺失量占总数的 2%~3%之间。




图 3 各站点各变量缺失数量热力图

对数据的缺失情况进行探究发现，数据中存在长时间的缺失情况。每个监测站点均存在长时间或短时间的数据缺失情况，下表为展示了其中两个监测站点的部分长时间缺失情况：

表 3 两个监测站点的部分长时间缺失情况

| 站点      | 特征  | 缺失时间段                                     | 连续缺失数据长度 |
|---------|-----|-------------------------------------------|----------|
| Meinong | AQI | 2020-11-17 02:00:00 ~ 2020-11-19 13:00:00 | 60 小时    |
|         |     | 2023-05-22 19:00:00 ~ 2023-05-24 17:00:00 | 47 小时    |

|         |                       |                                           |        |
|---------|-----------------------|-------------------------------------------|--------|
|         | PM <sub>2.5</sub>     | 2020-08-11 13:00:00 ~ 2020-08-14 14:00:00 | 74 小时  |
|         | PM <sub>10</sub>      | 2020-09-21 15:00:00 ~ 2020-09-25 11:00:00 | 93 小时  |
|         | winddirec             | 2023-12-06 00:00:00 ~ 2023-12-20 22:00:00 | 359 小时 |
| Zuoying | PM <sub>2.5</sub>     | 2020-08-03 15:00:00 ~ 2020-08-07 18:00:00 | 100 小时 |
|         | PM <sub>10</sub>      | 2023-07-24 14:00:00 ~ 2023-07-29 11:00:00 | 118 小时 |
|         | PM <sub>2.5_avg</sub> | 2021-06-04 14:00:00 ~ 2021-06-08 21:00:00 | 104 小时 |

本文使用一种基于时间序列特征的严格分级缺失值填充策略。对于短期随机缺失和长期连续缺失问题，短期缺失（ $\leq 6$  小时）使用使用线性插值，短时间缺失空气污染物具有很强的自相关性，短时间内不会突变。线性插值最简单且误差最小。长期缺失（ $> 6$  小时）则放弃线性插值，使用历史同期均值填充，因为长期缺失可能跨越关键的时间事件，空气质量具有显著的季节性和日周期性，而历史周期性均值更能反映该时间点的典型数值。通过这种分级填充确保了短期缺失能够保持时序连续性，而长期缺失则能够更好地反映污染物浓度在季节和日周期上的典型周期模式，从而提高了填充数据的代表性和模型的可靠性。

在填补缺失值时发现 PM<sub>2.5</sub> 指标列存在非数值情况，即“ND”，如下图 4 所示 ND 通常意味着污染物浓度低于仪器的最低检测限，或者是仪器故障没读数。共 11 个非数值数据，直接将其转换为 NaN，然后参与到“插值/历史同期填充”流程。




图 4 PM2.5 出现非数值位置

仍剩余 pollutant 与 status 特征还未处理其缺失情况，缺失情况如下图 5 和 6 所示。虽然图 5 显示其缺失情况高达 43.17%，但这并不都是缺失，因为该列是污染物情况，不是每天都被高污染物影响，status 数据缺失处的填补要根据 AQI 列来决定。




图 5 pollutant 列数据缺失情况




图 6 status 列数据缺失情况

最后，由于数据中的异常值会影响对 pollutant 与 status 中类别情况的判断，故考虑先对数据进行异常值处理，如下图 7 所示，通过箱线图展示了数值型特征数据的分布情况，若按照 IQR 方法进行剔除数据，则会将许多有价值的数据删去。故本文采用物理范围法对异常值进行剔除，下图的箱线图中展示了不同污染指标的范围，可以看到全部数值型特征均未超过上界，但存在部分特征的数值小于下界。如下图 8 所示，共计 474 个异常值，其中 AQI 有 277 个异常值，NO<sub>2</sub> 有 1 个异常值，SO<sub>2</sub> 有 26 个异常值，NO 有 168 个异常值，SO<sub>2\_avg</sub> 有 2 个异常值。将其全部转换未 Nan 值，使用分级缺失值填充策略进行填补。




图 7 各数值型变量异常值分布（箱线图）




图 8 各变量异常值数量统计（物理范围法）

最后，对 pollutant 与 status 特征进行处理。status 特征缺失数量为 2427，pollutant 特征缺失数量为 88328。因为 status 数据缺失处的填补要根据 AQI 来决定，如下表 4 所示：

表 4 空气质量等级与 AQI 数值范围对应表

| 空气质量等级                         | AQI 数值范围                |
|--------------------------------|-------------------------|
| Good                           | $AQI \leq 50$           |
| Moderate                       | $51 \leq AQI \leq 100$  |
| Unhealthy for Sensitive Groups | $101 \leq AQI \leq 150$ |
| Unhealthy                      | $151 \leq AQI \leq 200$ |
| Very Unhealthy                 | $201 \leq AQI$          |

据此，status 特征的缺失值已填补完成，最后个类别数据数量如下表 5 所示。status 列中等级为“Good”所对应的 pollutant 列应为无污染，所以对 pollutant 列进行填充“Zero Pollution”，填补过后 pollutant 特征仅缺失 1263 条数据。

表 5 各空气质量等级样本数量统计

| 空气质量等级                         | 样本数量（条） |
|--------------------------------|---------|
| Moderate                       | 96395   |
| Good                           | 87065   |
| Unhealthy for Sensitive Groups | 19597   |
| Unhealthy                      | 1541    |
| Very Unhealthy                 | 2       |

对于首要污染物（Pollutant）缺失值的填补，本研究采用空气质量分指数（IAQI）计算方法进行判定。根据美国环境保护署和台湾环保署发布的空气质量指标标准，各污染物的 IAQI 通过分段线性插值公式计算：

$$IAQI_p = \frac{I_{high} - I_{low}}{C_{high} - C_{low}} \times (C_p - C_{low}) + I_{low}$$

其中， $C_p$  为污染物 p 的实测浓度， $C_{high}$  和  $C_{low}$  分别为该浓度所属区间的浓度分界点下限和上限， $I_{high}$  和  $I_{low}$  为对应的 IAQI 分界点。本研究计算了 PM<sub>2.5</sub>、PM<sub>10</sub>、O<sub>3</sub>（小时值及 8 小时滑动平均）、NO<sub>2</sub> 和 SO<sub>2</sub> 共六种污染物的 IAQI 值，并将 IAQI 最大值对应的污染物判定为该时刻的首要污染物。当  $AQI \leq 50$  且无明显首要污染物时，将其标记为“Zero Pollution”。该方法共填补了 1263 条缺失记录，确保了数据的完整性和分析的可靠性。如下表 6 显示了这 1263 条缺失数据的去向，其中，主要还是流入 PM<sub>2.5</sub> 中。如下表 7 展示了完全填补后的污染物分布情况。

表 6 新填充的污染物分布统计

| 首要污染物             | 样本数量（条） |
|-------------------|---------|
| PM <sub>2.5</sub> | 1145    |
| Ozone (8hr)       | 97      |
| PM <sub>10</sub>  | 21      |

表 7 污染物最终分布统计

| 污染物                                 | 样本数量（条） |
|-------------------------------------|---------|
| PM <sub>2.5</sub>                   | 101735  |
| Zero Pollution（无污染）                 | 87065   |
| Ozone (8hr)                         | 13633   |
| PM <sub>10</sub>                    | 1790    |
| Nitrogen Dioxide (NO <sub>2</sub> ) | 295     |
| Sulfur Dioxide (SO <sub>2</sub> )   | 78      |

2.3 探索性数据分析

2.3.1 单变量分析

本研究对高雄市 2020 年至 2024 年的空气质量数据进行了全面的单变量分析，以揭示其核心的统计特征、时间演变规律以及空间异质性。

高雄市空气质量已稳定处于中国大陆 AQI 标准的“良”水平（年均值 55~65），五年改善幅度约 10~15 个 AQI 单位，整体脱离“中度污染”区间，但空间高度分异、季节剧烈波动、颗粒物与臭氧双峰并存的结构性特征依然突出。空间分布呈现极其稳定的“南高北低”格局如下图所示。



图 9 AQI 空间分布地图

南部林园区与小港区常年 AQI 高于 65~70，属于全市污染最重核心区。五站点雷达图与年度趋势线如下图 10，将这种分异刻画得淋漓尽致：林园区在 PM<sub>2.5</sub>、PM<sub>10</sub>、NO<sub>2</sub>、CO 四项上几乎全部触及或突破外圈，形如“饱满多边形”，小港与前金次之，左营明显内缩，而美浓几乎缩成一个小三角。2020-2024 五年间，林园区 AQI 从近 75 一路降至 62，降幅全市最大，显示炼油、石化与钢铁行业深度减排成效显著；美浓则几乎横盘在 50~55 之间，体现典型山区清洁背景值。




图 10 各站点主要污染物平均浓度及 AQI 年度均值趋势

时间维度上形成了近乎教科书级的“冬高夏低、U 型谷底”规律，月度曲线如下图 11 所示每年 12 月急剧拉升，翌年 1-2 月达到顶峰，6-8 月断崖式跌至谷底，形成几乎完美对称的“U”形。




图 11 月度均值变化趋势

污染物贡献随季节精准切换如下图 12 所示：冬季 PM<sub>2.5</sub> 与 PM<sub>10</sub> 高度突出，贡献率常超

70%，NO<sub>2</sub> 与 CO 也明显升高；夏季臭氧 O<sub>3</sub> 及 O<sub>3</sub>\_8hr 取代颗粒物成为最高子指数，峰值贡献率可达 90%以上；春秋季则呈现 NO<sub>2</sub>、CO 与颗粒物“三分天下”的均衡状态。这种“冬颗粒、夏臭氧”的双峰模式已成为高雄最显著的污染特征。




图 12 各污染物季节差异

长期趋势持续向好且结构清晰如下图 13 所示。2020-2024 年间,PM<sub>2.5</sub> 年均浓度下降约 35%，PM<sub>10</sub> 下降约 28%，NO<sub>2</sub> 下降约 25%，SO<sub>2</sub> 与 CO 降幅更是高达 40%~50%，反映燃煤电厂超低排放、工业窑炉提标改造、港口岸电与低硫油切换等硬措施的叠加成效。唯一逆势上升的是臭氧及其 8 小时值（O<sub>3</sub>\_8hr），五年上升约 8%~12%，显示 VOCs 与 NO<sub>x</sub> 光化学反应链正在成为新的主导因子。




图 13 污染物年度均值变化趋势

气象成因是冬季高值的核心外因。高雄全年盛行东北季风如下图 14 所示，N~NE 方向频

率最高，风速多集中在 5.5~11m/s，有利于污染物向西南快速输送与扩散；但冬季东北风更强、更稳定，常伴随地面辐射逆温与混合层高度降低，导致颗粒物在北部工业带与港口区持续累积。西南向（SW~WSW）虽全年频率最低，一旦出现往往风速<2.7m/s，伴随静稳与回流，成为冬季短时重污染过程的典型气象背景。




图 14 风玫瑰图

在明确高雄“南高北低”的空间污染格局后，通过新增的三张站点关联分析图，进一步探究美浓（Meinong，清洁背景参考站）与林园（Linyuan）、前金（Qianjin）、左营（Zuoying）、小港（Xiaogang）四个重污染站点的污染关联特征，核心结论为：美浓虽为山区清洁背景站，但与其他重污染站点存在显著的污染关联，受区域污染传输影响明显。

图 15 以数值标注直观呈现 5 个站点间 AQI 的线性相关程度，核心解读聚焦美浓与其他重污染站点的关联。美浓与四大重污染站点的 AQI 相关系数介于 0.820-0.832 之间（与前金最高 0.832，与小港最低 0.820），均处于高相关水平（通常  $|r| \geq 0.8$  为强相关）。四大重污染站点间的相关系数更高（0.896-0.959），体现重污染区域内部污染同步性极强；而美浓作为理论上的清洁背景站，仍与它们保持强相关，直接印证了美浓的空气质量会被其他重污染站点的污染扩散所影响，区域污染传输效应显著。相关系数未达到完全同步（ $<0.9$ ），且美浓 AQI 均值更低，说明其清洁背景属性仍起作用，污染影响是“区域传输叠加”而非自身排放主导。




图 15 AQI 相关系数矩阵（热力图）

图 16 展现了 2020 年 1 月（冬季污染高发期）五大站点的 AQI 实时波动趋势，进一步佐证美浓与重污染站点的关联。时间波动高度同步：四大重污染站点的 AQI 峰值（部分时段接近 100）与谷值出现时间完全一致，而美浓的 AQI 曲线虽整体处于低位（多数时段 50-60），但波动节奏与前者完全同步——当重污染站点 AQI 飙升时，美浓 AQI 也随之小幅上升，当重污染站点 AQI 下降时，美浓也同步回落。污染传输痕迹明显：1 月中旬出现的两次污染高峰中，美浓 AQI 随林园、小港的污染峰值同步抬升，印证了冬季静稳天气下，重污染区域的污染物通过大气传输影响到美浓所在的山区，与相关系数矩阵的结论相互呼应。




图 16 2020 年 1 月 AQI 时间序列对比图解释

图 17 图通过统计各站点 AQI 的出现频次与分布范围，呈现美浓受其他站点影响的实际表现。均值差异显著：美浓 AQI 均值仅 52.5，远低于四大重污染站点（60.8-62.7），符合清洁背景站的基础特征。分布范围印证影响：美浓的 AQI 分布虽集中在 30-70 的低污染区间，但仍存在部分时段 AQI 突破 80，甚至接近 100 的情况，而这些高值区间与四大重污染站点的常见 AQI 范围高度重叠，说明美浓的高污染时段并非自身产生，而是受其他重污染站点的污染扩散影响导致。分布形态呼应关联：四大重污染站点的 AQI 分布更偏向高值区间且分布较宽，美浓则偏向低值但存在“长尾延伸”（高值端有少量分布），这一“核心清洁+高值受影响”的形态，进一步证明美浓与其他重污染站点的污染关联。




图 17 各站点 AQI 分布直方图解释

综上，高雄市空气污染已完成从“煤烟+重工业颗粒物型”向“颗粒物显著下降、光化学臭氧逐渐抬头”的历史性转型。当前治理格局可概括为：空间上北部沿海仍是绝对重点，时间上冬季颗粒物与夏季臭氧构成双线作战，污染物上一次排放已大幅压减、次生转化成为新挑战。未来实现“常优”的关键路径在于：持续深化北部石化、钢铁、港口船舶减排，强化冬季应急与夏季 VOCs+NO<sub>x</sub> 协同管控，同时利用东北季风的自然扩散优势，构建“冬防颗粒、夏控臭氧、常年削峰”的立体化治理体系。

### 2.3.2 多变量分析

为明确各污染物与空气质量指数（AQI）的关联强度，以及不同污染物间的相互作用，对核心污染物指标进行相关性计算并绘制热力图，如下图 18 所示。




图 18 相关性矩阵热力图

从相关性矩阵热力图可得出以下核心结论：

（1）关键影响污染物：PM<sub>2.5</sub>与AQI的相关系数高达0.87，是影响空气质量指数的最核心污染物；其次为PM<sub>10</sub>（与AQI相关系数0.79），二者均属于颗粒物污染物，其浓度变化对AQI的主导作用显著，这与颗粒物可长期悬浮于大气、直接影响空气质量等级的特性一致。

（2）气态污染物贡献：一氧化碳（CO）与AQI相关系数为0.62，氮氧化物（NO<sub>2</sub>）为0.48，二氧化硫（SO<sub>2</sub>）为0.22，表明气态污染物对AQI存在一定贡献，但影响程度明显低于颗粒物；其中CO与NO<sub>2</sub>相关系数达0.74，推测二者可能具有共同排放源（如机动车尾气、工业燃烧）。

（3）臭氧特殊性：臭氧（O<sub>3</sub>）与PM<sub>2.5</sub>、PM<sub>10</sub>的相关系数仅为0.2，与NO<sub>2</sub>呈弱负相关（-0.18），反映出臭氧污染的形成机制与颗粒物、其他气态污染物存在差异——臭氧主要通过

光化学反应生成，受光照、温度等气象条件影响更大，而非直接排放导致。

### 2.3.2.1 影响 AQI 的特征重要性排序

通过线性回归特征系数与随机森林特征重要性图，如下图 19 所示，从“线性贡献”与“综合重要性”两个维度，量化各变量对 AQI 的影响权重：

（1）核心驱动特征：随机森林模型中，PM<sub>2.5</sub>的特征重要性分数最高（接近 0.8），远超其他变量；线性回归模型中，PM<sub>2.5</sub>的正系数值达 15，表明其浓度每升高 1μg/m<sup>3</sup>，AQI 平均上升 15 个单位，进一步验证 PM<sub>2.5</sub>是影响 AQI 的关键变量。

（2）次要影响特征：PM<sub>10</sub>（重要性分数 0.35，线性系数 8）、CO（重要性分数 0.25，线性系数 5）、NO<sub>2</sub>（重要性分数 0.2，线性系数 3）为次要驱动因素，且均呈正相关，即浓度升高会显著推高 AQI；风速作为唯一负相关特征（线性系数-2），重要性分数 0.15，表明风速提升可通过扩散效应降低 AQI，是关键的气象调控因素。

（3）低影响特征：时间特征（小时、day\_of\_week）重要性分数均低于 0.1，线性系数小于 1，对 AQI 的综合影响较弱；SO<sub>2</sub>、O<sub>3</sub>等变量重要性排名靠后，与前文相关性分析结论一致，可作为建模的辅助特征而非核心输入。




图 19 线性回归特征系数与随机森林特征重要性图

### 2.3.3 聚类分析

（1）站点聚类（按污染特征对 sitename 聚类）

Linyuan、Meinong、Qianjin、Xiaogang、Zuoying 5 个监测站点均归类为交通主导型站点，无工业影响型及清洁背景站点，表明高雄监测覆盖区域的空气质量污染源高度集中于交通排放。

图 20 以色彩深浅（或数值标注）直观呈现了 5 个站点 6 类核心污染物（PM<sub>2.5</sub>、PM<sub>10</sub>、O<sub>3</sub>、

NO<sub>2</sub>、SO<sub>2</sub>、CO)的平均浓度分布特征。交通关联污染物浓度突出，各站点的NO<sub>2</sub>(机动车尾气特征污染物)浓度介于10.2-17.4μg/m<sup>3</sup>(Xiaogang 最高)、CO 浓度均稳定在0.3mg/m<sup>3</sup>，显著高于清洁背景区域典型水平，印证了交通排放的主导作用。颗粒物浓度存在站点差异，Linyuan 的PM<sub>2.5</sub>平均浓度达40μg/m<sup>3</sup>，为所有站点最高，推测与该区域交通流量更大或道路扬尘叠加有关；其余站点PM<sub>2.5</sub>、PM<sub>10</sub>浓度集中在19.8-32.7μg/m<sup>3</sup>，整体呈现“颗粒物+气态交通污染物”协同污染特征。无工业污染信号，SO<sub>2</sub>(工业燃煤/化工特征污染物)浓度普遍偏低(1.3-2.8μg/m<sup>3</sup>)，各站点污染物构成比例一致，无单一污染物异常高值的工业型站点特征，进一步佐证污染来源以交通为主。




图 20 各站点污染物平均浓度热图

## (2) 时段聚类 (按日期/时间聚类)

时段聚类共划分 3 类污染等级，其中优良时段占比 44.5% (18043 个)、重污染时段占比 28.8% (11689 个)、轻度污染时段占比 26.7% (10835 个)，重污染时段集中于早高峰 7:00-9:00。

图 21 柱状图清晰展现了三类时段下各污染物的平均浓度差异，其中重污染时段污染物浓度显著叠加。早高峰 (7-9 点) 对应的重污染时段中，PM<sub>2.5</sub>、PM<sub>10</sub> 浓度接近 60 μg/m<sup>3</sup> 和 50 μg/m<sup>3</sup>，较优良时段 (约 10 μg/m<sup>3</sup>、15 μg/m<sup>3</sup>) 高出 5-6 倍，NO<sub>2</sub> 浓度同步达到峰值，与早高峰机动车流量激增、尾气排放集中直接相关，时段浓度与交通流量强相关。优良时段各类污染物浓度均处于最低水平，反映非高峰时段 (如夜间、周末) 交通排放减少后的空气质量状态；轻

度污染时段污染物浓度介于两者之间，多对应平峰时段，交通排放强度中等，无明显污染物叠加效应，O<sub>3</sub>浓度时段特征特殊。O<sub>3</sub>作为二次污染物，在重污染时段浓度未出现峰值（反而低于部分轻度污染时段），推测早高峰高浓度NO<sub>2</sub>（强氧化剂消耗剂）抑制了O<sub>3</sub>生成，符合“NO<sub>2</sub>-O<sub>3</sub>光化学反应平衡”规律。




图 21 不同时段污染物浓度对比

### 三、特征工程

空气质量预测是一个复杂的时空序列预测问题，其精度高度依赖于能否有效捕捉污染物浓度变化的多维度驱动因素。特征工程作为空气质量预测模型性能优化的核心环节，会直接影响模型对污染演变规律的捕捉能力。为构建一个稳健且高精度的多站点AQI预测系统，本研究针对高雄市前金、林园、美浓、小港、左营五个监测站点的小时级AQI数据，构建了一套融合时间依赖性、空间相关性、物理机制、统计规律的多维度特征工程体系。通过滞后相关性分析、数据标准化、特征筛选等关键步骤，最终形成结构化特征集，为后续预测模型提供高质量输入。

本次研究的特征工程体系以“数据驱动+物理机制融合”为核心，遵循“从数据预处理到特征优化”的全流程标准化逻辑，具有以下优势：

- （1）普适性：特征构建不依赖特定模型的结构特性，适配各类预测模型，可迁移至不同区域、不同时间尺度的空气质量预测任务；
- （2）机制导向：深度结合大气污染的物理演变规律，如污染物随时间累积、随气流扩散的特性，确保特征具有明确的物理意义，而非纯数据驱动的无意义特征；
- （3）多维度覆盖：全面整合时间、空间、气象、统计四大核心维度，避免单一维度特征

的信息局限。

### 3.1 时间特征工程

时间特征是空气质量预测的基础，能够有效体现由人类活动、气象条件日变化和季节更迭引起的周期性污染规律。影响 AQI 的重要污染物浓度往往呈现出日内、周内、年内的周期性变化，同时受人类活动（如周末与工作日差异）影响显著，本研究通过多形式时间特征编码，充分挖掘时间维度的预测信息。

表 8 展示了时间特征的三个类别，其中基础时间特征就是从原数据集中的 date 变量列进行年份、月份、星期特征的提取，均为离散型整数特征。

为了解决离散时间的“边界效应”与“连续性缺失”的问题，采用三角函数编码将离散周期特征转化为连续矢量，即循环特征编码特征中的变量。

根据周内周期规律，一般情况下工作日工业生产、交通流量稳定，污染浓度波动相对规律；周末人类活动减少，污染浓度整体偏低且波动平缓。因此工作日和周末作为人类活动强度突变的关键时间节点，需要构建周末节点标记以区分“常规时段”与“特殊时段”的污染驱动差异。

表 8 时间特征详细说明

| 特征类别   | 变量名称       | 变量定义                                         |
|--------|------------|----------------------------------------------|
| 基础时间特征 | hour       | 一天中的小时数                                      |
|        | month      | 一年中的月份数                                      |
|        | dayofweek  | 一周中的天数                                       |
| 循环特征编码 | hour_sin   | $hour\_sin = \sin(2\pi \times hour / 24)$    |
|        | hour_cos   | $hour\_cos = \cos(2\pi \times hour / 24)$    |
|        | month_sin  | $month\_sin = \sin(2\pi \times month / 12)$  |
|        | month_cos  | $month\_cos = \cos(2\pi \times month / 12)$  |
|        | day_sin    | $day\_sin = \sin(2\pi \times dayofweek / 7)$ |
|        | day_cos    | $day\_cos = \cos(2\pi \times dayofweek / 7)$ |
| 特殊时间标记 | is_weekend | 周末为 1，工作日为 0                                 |

### 3.2 风场特征工程

风场是影响大气污染物传输、扩散、累积的核心物理驱动因子，其“风向+风速”的复合特性直接决定了污染物的空间迁移路径与扩散强度——风向主导污染物的输送方向，风速决定污染物的扩散效率。

风场特征工程的核心目标是将“风向+风速”的原始复合信息，转化为模型可识别、可量

化的结构化特征，精准捕捉风场对空气质量的物理驱动机制，为 ARIMA、Random Forest、LightGBM、LSTM、Transformer 五类模型提供兼具物理意义与适配性的输入，弥补纯数据驱动模型在“物理机制建模”上的短板。

因此，在风场特征中完成了以下四方面工作：基于监测数据中的风场指标，筛选并整理目标站点与邻居站点的原始风场数据，为“区域风场协同效应”建模提供数据支撑；通过角度单位转换将风向从“度”转换为“弧度”，消除角度单位的量纲差异；基于三角函数将其分解为水平东西向和垂直南北向两个正交分量，通过两个分量的组合完整表征风场的输送特性——水平分量（Wind\_X）反映污染物在东西方向的输送强度，垂直分量（Wind\_Y）反映污染物在南北方向的输送强度；结合空气质量的空间扩散特性，将目标站点与邻居站点的风场特征进行整合，构建区域风场协同特征。

表 9 风场特征工程详细说明

| 特征类别   | 变量名称           | 变量定义                                      |
|--------|----------------|-------------------------------------------|
| 原始风场特征 | winddirec      | 目标站点的风向（原始角度）                             |
|        | windspeed      | 目标站点的风速                                   |
|        | [站点]_winddirec | 邻居站点的风向                                   |
|        | [站点]_windspeed | 邻居站点的风速                                   |
| 矢量分解特征 | Wind_X         | $Wind\_X=windspeed*\cos(winddirec_{rad})$ |
|        | Wind_Y         | $Wind\_Y=windspeed*\sin(winddirec_{rad})$ |
|        | [站点]_Wind_X    | 邻居站点风场水平分量                                |
|        | [站点]_Wind_Y    | 邻居站点风场垂直分量                                |

3.3 滞后特征

滞后特征是捕捉空气质量时间依赖性的核心载体，其本质是利用“历史污染状态”预测“未来污染演变”——污染物浓度的变化具有显著的连续性与累积性，当前时刻的污染水平不仅受即时排放、气象条件影响，更与短期、中期、长期的历史污染累积密切相关。

通过构建滞后特征，可以量化污染的累积效应、趋势延续与周期重复规律，提升预测结果的可解释性与实用价值。表 10 的滞后特征 AQI/PM<sub>2.5</sub>\_lag\_1/3/6/12/24/36/48 分别表示了目标站点 1/3/6/12/24/36/48 小时前的 AQI 值/PM<sub>2.5</sub> 浓度，其中短期滞后特征可量化为“即时累计”，中期的数值上升和下降则能说明污染的变化趋势，污染变化还存在显著的日周期规律，因此需要捕捉日周期规律。

表 10 滞后特征详细说明

| 特征类别       | 变量名称         | 特征意义                                      |
|------------|--------------|-------------------------------------------|
| AQI 滞后特征   | AQI_lag_1    | 捕捉短期即时污染累积效应                              |
|            | AQI_lag_3    | 捕捉短期污染累积效应                                |
|            | AQI_lag_6    | 捕捉中期污染累积效应                                |
|            | AQI_lag_12   | 捕捉中期污染累积效应                                |
|            | AQI_lag_24   | 捕捉日周期污染累积效应（昨日同期污染水平对今日的影响）               |
|            | AQI_lag_36   | 捕捉跨日中期污染累积效应                              |
|            | AQI_lag_48   | 捕捉跨日长期污染累积效应，覆盖两天的污染累积影响                  |
| PM2.5 滞后特征 | PM2.5_lag_1  | PM2.5 是 AQI 核心贡献因子，捕捉短期 PM2.5 累积对 AQI 的影响 |
|            | PM2.5_lag_3  | 捕捉短期 PM2.5 累积效应                           |
|            | PM2.5_lag_6  | 捕捉中期 PM2.5 累积效应                           |
|            | PM2.5_lag_12 | 捕捉中期 PM2.5 累积效应                           |
|            | PM2.5_lag_24 | 捕捉日周期 PM2.5 累积效应                          |
|            | PM2.5_lag_36 | 捕捉跨日中期 PM2.5 累积效应                         |
|            | PM2.5_lag_48 | 捕捉跨日长期 PM2.5 累积效应                         |

3.4 滚动统计量

滚动统计量，又称滑动窗口统计量是捕捉空气质量时间序列趋势性、波动性与累积效应的核心特征，其本质是基于固定长度的“滑动窗口”，对历史时间序列数据进行统计计算，将离散的单点数据转化为反映“局部窗口内全局规律”的结构化特征。

滚动统计量的价值不仅在于将单点数据转化为统计特征，更在于通过趋势提炼、波动量化、多尺度覆盖，精准捕捉污染演变的全局规律，同时适配五类模型的差异化特性，提升预测精度、可解释性与泛化能力。

表 11 中呈现了两种滚动统计量：滚动平均值和滚动标准差，其中滚动平均值 roll\_mean 是窗口内所有观测值的算术平均值，核心反映窗口内污染的平均水平与整体趋势；滚动标准差 roll\_std 是窗口内所有观测值的标准差，核心反映窗口内污染的波动强度与稳定性。

表 11 滚动统计量详细说明

| 特征类别   | 变量名称             | 特征意义              |
|--------|------------------|-------------------|
| 滚动均值特征 | AQI_roll_mean_6  | 反映短期污染平均水平，捕捉污染趋势 |
|        | AQI_roll_mean_12 | 反映中期（12 小时）污染平均水平 |
|        | AQI_roll_mean_24 | 反映日周期污染平均水平，消除短期波 |

|         |                  |                     |
|---------|------------------|---------------------|
|         |                  | 动干扰                 |
|         | AQI_roll_mean_48 | 反映跨日污染平均水平，捕捉长期趋势   |
|         | AQI_roll_std_6   | 反映短期污染波动强度，识别污染突变情况 |
| 滚动标准差特征 | AQI_roll_std_12  | 反映中期污染波动强度          |
|         | AQI_roll_std_24  | 反映日周期污染波动强度         |
|         | AQI_roll_std_48  | 反映跨日污染波动强度，识别长期波动规律 |
|         |                  |                     |

3.5 邻居站点聚合特征

邻居站点聚合特征是指：在明确目标站点的邻居站点范围后，基于前置滞后相关性分析得到的“最优滞后时间”对邻居站点 AQI 数据进行时间对齐，再通过统计聚合方法计算得到的反映区域污染状态的特征。

邻居站点聚合特征的本质是“空间信息整合与区域规律提炼”——通过整合周边站点的污染数据，将单一站点的“局部视角”拓展为区域的“全局视角”，其价值定位体现在：从“单点孤立”到“区域协同”，打破单一站点数据的局限性，捕捉区域污染的整体水平与分布规律；量化污染扩散的空间关联，将“上游站点污染到下游站点扩散”的物理过程转化为可量化的特征，为模型提供空间因果支撑；补充区域污染背景信息，目标站点的污染浓度不仅受本地排放影响，更受区域污染背景制约。

表 12 中 neighbor\_AQI\_mean/std/max/min 分别定义了所有邻居站点经时间对齐后的 AQI 均值/标准差/最大值/最小值，其中邻居均值直接反映区域污染的整体水平，邻居标准差可反映区域的分布均匀性，邻居最大值可捕捉区域内的极端污染点。

表 12 邻居站点聚合特征详细说明

| 特征类别   | 变量名称              | 意义                              |
|--------|-------------------|---------------------------------|
| 邻居聚合特征 | neighbor_AQI_mean | 反映目标站点周边区域的平均污染水平，体现区域污染背景值     |
|        | neighbor_AQI_std  | 反映周边区域污染分布的均匀性，标准差越大说明区域污染差异越显著 |
|        | neighbor_AQI_max  | 捕捉周边区域的极端污染水平，预警目标站点可能面临的污染峰值   |
|        | neighbor_AQI_min  | 反映周边区域的最低污染水平，为目标站点污染下限提供参考     |

本研究中的特征工程之间并非孤立存在，而是形成紧密协同的互补关系：时间特征搭建污染演变的周期框架，明确“何时变化”的节律基础；风场特征量化污染物传输的物理机制，解答“为何扩散”的动力逻辑；滞后特征捕捉特定历史时刻的累积效应，揭示“从何而来”的时序因果；滚动统计量提炼历史窗口的趋势与波动，强化“如何变化”的规律支撑；邻居站点聚合特征覆盖区域污染的空间关联，提供“何地影响”的协同背景。

时间特征、风场特征、滞后特征、滚动统计量、邻居站点聚合特征共同构成了覆盖“时间-空间-物理-统计”四维一体的空气质量预测特征体系。其对建模的总体意义在于：通过多维度、机制导向的特征设计，将空气质量演变的核心规律转化为模型可识别的结构化信息，既打破了单一维度数据的局限，又适配了 ARIMA、Random Forest、LightGBM、LSTM、Transformer 五类模型的差异化特性——既为时序模型补充物理与空间信息，为传统机器学习模型提供高表征能力的衍生特征，为深度学习模型搭建“时序-空间-物理”的联合建模基础，又通过标准化、鲁棒性处理降低模型训练噪声与过拟合风险，最终实现预测精度、泛化能力与可解释性的同步提升。

五类特征相互印证、层层补充，既完整还原了“区域污染产生、风场输送、时序累积、周期演变、趋势呈现”的全链条污染过程，又通过“滞后特征、时间特征、滚动统计量、邻居聚合特征、风场特征”的多维协同，为各类模型提供了兼具深度与广度的信息输入，成为空气质量精准预测的核心支撑。

## 四、模型建立与应用

### 4.1 ARIMA 模型

ARIMA (Autoregressive Integrated Moving Average) 模型作为经典的时间序列预测模型，在时序数据趋势捕捉与规律拟合领域具备成熟的技术体系。与 Transformer 等深度学习模型依赖数据驱动的特征提取不同，ARIMA 模型基于时序数据的自相关性与差分平稳性假设，通过自回归、差分和移动平均的组合实现对序列的建模，其核心优势使其在空气质量 AQI 这类具有明显时序波动特征的预测任务中具备独特的应用价值：

(1) 平稳性适配：通过差分运算 ( $d$  阶) 可将非平稳的空气质量时序数据转化为平稳序列，有效消除数据中的趋势项与周期性波动，为后续建模奠定基础；

(2) 自相关捕捉：自回归项 ( $p$  阶) 能够挖掘 AQI 数据自身的历史关联，捕捉相邻时间步长间的浓度传递规律；

(3) 噪声修正：移动平均项 ( $q$  阶) 可对模型预测误差进行平滑修正，降低随机扰动对预

测结果的影响，提升预测稳定性。




图 22 ARIMA 整体结构

本研究基于 ARIMA 模型架构，针对 5 个空气质量监测站点（Xiaogang、Linyuan、Qianjin、Zuoying、Meinong）的 AQI 时序特性进行定制化参数配置，以实现精准的 24 小时 AQI 预测。为充分适配各站点的时序波动差异，模型采用站点专属的阶数组合，并依托严格的平稳性与白噪声检验流程构建预测体系。模型以历史小时级 AQI 数据为基础，采用滑动窗口法划分训练与预测样本，同时融合分段抽样验证策略保障模型泛化能力。

模型输入序列首先经过平稳性检验，对非平稳序列执行 1 阶差分运算以消除趋势，再通过白噪声检验排除无效序列，最终针对不同站点的自相关与偏自相关特性拟合专属 ARIMA 子模型。为提升模型运算效率与内存利用率，模型启用低内存计算模式，同时采用创新极大似然估计法完成参数迭代优化，确保模型参数的精准性与稳定性，ARIMA 模型的详细参数配置，涵盖输入输出、模型阶数、算法配置及验证策略等核心维度。

如下表 13 为模型的详细参数。

表 13 模型超参数与结构配置

| 类别       | 参数名称             | 参数值                                                                                |
|----------|------------------|------------------------------------------------------------------------------------|
| 输入/输出    | 历史训练窗口           | 48 小时                                                                              |
|          | 预测时长             | 24 小时                                                                              |
|          | 数据频率             | 1 小时 (Hourly)                                                                      |
| ARIMA 模块 | 模型名称             | Autoregressive Integrated Moving Average                                           |
|          | 站点特定阶数 (p, d, q) | Xiaogang(5,1,1), Linyuan(3,1,1), Qianjin(3,1,1),<br>Zuoying(1,1,0), Meinong(5,1,2) |

|               |               |
|---------------|---------------|
| 自回归阶数 (p) 范围  | 1 ~ 5         |
| 差分阶数 (d)      | 1 (针对非平稳序列)   |
| 移动平均阶数 (q) 范围 | 0 ~ 2         |
| 趋势项 (Trend)   | 无 (已通过一阶差分消除) |

如下表 14 呈现了 ARIMA 模型在 Xiaogang、Linyuan、Qianjin、Zuoying、Meinong 这 5 个空气质量监测站点的综合预测表现，本研究选取 RMSE、MAE、 $R^2$  三项核心评价指标，从误差大小与拟合程度两个维度，全方位衡量模型在不同站点的预测精准度。

从整体数据来看，ARIMA 模型在 5 个监测站点的预测能力呈现出明显的差异化特征，整体处于中等拟合水准：Xiaogang 站点的综合表现最为亮眼，其  $R^2$  值达到 0.5949，在所有站点中居于首位，这表明该模型对 Xiaogang 站点 AQI 时序变化规律的解释与适配能力最强；与之形成对比的是 Zuoying 站点，其  $R^2$  仅为 0.4115，反映出模型对该站点 AQI 数据的特征捕捉存在明显不足。

在误差维度，Xiaogang 站点的数值偏差最小，RMSE 低至 18.919，MAE 为 13.348，预测值与实际值的偏离程度最可控；Zuoying 站点的预测误差最为显著，RMSE 高达 24.307，MAE 也达到 15.843，这一结果侧面印证了该站点 AQI 数据的波动特性更为复杂，传统 ARIMA 模型的线性建模框架难以充分适配其非线性变化模式。

整体而言，各站点  $R^2$  值集中在 0.4~0.6 区间，说明模型可有效挖掘 AQI 数据的基础时序关联，但面对复杂的波动场景时，其拟合能力存在明显局限，后续需结合多源特征融合或模型融合策略进一步提升性能。

表 14 各站点 ARIMA 模型预测评价指标

| 评价指标  | Meinong | Zuoying | Qianjin | Xiaogang | Linyuan |
|-------|---------|---------|---------|----------|---------|
| RMSE  | 19.718  | 24.307  | 22.809  | 18.919   | 21.728  |
| MAE   | 12.715  | 15.843  | 15.259  | 13.348   | 14.947  |
| $R^2$ | 0.4654  | 0.4115  | 0.5391  | 0.5949   | 0.5662  |

如下图 23 分别呈现了 Xiaogang、Linyuan、Qianjin、Zuoying、Meinong 这 5 个空气质量监测站点中典型样本的“实际 AQI 值”与“ARIMA 模型预测 AQI 值”的时序拟合态势，其中横轴对应未来 24 小时的预测时长，可直观反映模型在不同时间跨度下的数值匹配能力。




图 23 站点样本拟合图

如下表 15 进一步拆解了 ARIMA 模型在 4 个不同预测时长区间（1-6h、7-12h、13-18h、19-24h）的性能表现，本研究沿用 RMSE、MAE、 $R^2$  三项核心指标，深度剖析模型预测精度随时间跨度延伸的演变规律，为模型在短期实时预警、长期趋势研判等不同应用场景的适配性提供量化依据。从指标数据可清晰发现，ARIMA 模型的预测能力随预测时长的增加呈现出显著的衰减特征，且不同时间段的性能表现差异悬殊。

表 15 不同时间段不同站点评价指标

| 评价指标  | 时间段    | Xiaogang | Linyuan | Qianjin | Zuoying | Meinong |
|-------|--------|----------|---------|---------|---------|---------|
| RMSE  | 1-6h   | 10.4828  | 13.2432 | 11.963  | 12.4299 | 9.801   |
| MAE   |        | 6.9144   | 8.3952  | 7.6266  | 7.5321  | 6.4443  |
| $R^2$ |        | 0.8746   | 0.8477  | 0.8641  | 0.8373  | 0.8634  |
| RMSE  | 7-12h  | 16.7926  | 20.895  | 21.8331 | 22.344  | 18.2561 |
| MAE   |        | 12.1521  | 14.7741 | 15.085  | 15.8977 | 12.8943 |
| $R^2$ |        | 0.6661   | 0.6394  | 0.5854  | 0.4987  | 0.4896  |
| RMSE  | 13-18h | 18.6745  | 25.3173 | 24.2089 | 26.0329 | 19.9535 |
| MAE   |        | 13.5742  | 17.9278 | 16.9707 | 18.6722 | 14.1057 |
| $R^2$ |        | 0.5538   | 0.4487  | 0.5041  | 0.3384  | 0.4584  |
| RMSE  | 19-24h | 19.2059  | 25.8307 | 22.7442 | 26.583  | 19.3428 |
| MAE   |        | 14.0031  | 18.7599 | 16.1616 | 18.7902 | 13.5943 |
| $R^2$ |        | 0.5652   | 0.4215  | 0.538   | 0.2835  | 0.4989  |

下图 24 为折线图，直观呈现了 5 个监测站点在不同预测时间段的  $R^2$  值分布情况。从图中能够清晰看到，所有站点的  $R^2$  值均随预测时长的延长呈现出一致的递减态势：1-6h 时段  $R^2$  值处于全时段峰值，凸显短期预测的高精度优势；19-24h 时段  $R^2$  值滑落至谷底，印证了长期预测中误差累积对模型性能的削弱作用。

从站点维度来看，Xiaogang 站点在各预测时段的  $R^2$  值均保持相对高位，即便是 19-24h 的长期预测，其  $R^2$  仍能维持在 0.565 左右的较高水平；而 Zuoying 站点的  $R^2$  值整体处于低位，19-24h 时段仅为 0.283，这一结果或与该站点 AQI 数据波动的复杂性密切相关。该图清晰勾勒出模型预测性能随时间跨度延伸的衰减轨迹，为模型的场景化应用提供了直观的参考依据。




图 24 不同时间长度  $R^2$  预测效果

## 4.2 随机森林模型

随机森林（Random Forest）模型是由 Breiman 于 2001 年提出的一种集成学习方法，它通过构建多个决策树并将它们的结果进行组合，以获得更准确和稳定的预测结果。与单一的决策树模型相比，随机森林通过引入随机性（包括随机选取样本和随机选取特征）来降低过拟合风险，提高模型的泛化能力。随机森林在空气质量预测任务中展现出以下显著优势：

（1）强大的非线性建模能力：随机森林能够有效地捕捉空气质量数据中的非线性关系和复杂的交互效应，无需对数据分布做出假设，可以自适应地处理多种污染物浓度之间的复杂相互作用。

(2) 鲁棒性与抗噪声能力：由于集成学习的特性，随机森林对噪声数据和异常值具有较高的容忍度，能够在存在数据缺失或不准确的情况下保持相对稳定的预测性能。

(3) 内置特征重要性评估：随机森林可以自动评估各个特征对预测结果的重要性，为特征选择和数据理解提供直观的依据，有助于识别对 AQI 变化最为关键的影响因子。




图 25 随机森林整体结构

本研究基于随机森林回归模型，采用多步预测（Multi-step Forecasting）策略，一次性预测未来 24 小时 AQI 序列。为了捕捉空气质量数据的时空变化规律，本研究构建了包含时间特征、滞后特征、统计特征的多维特征集。采用滑动窗口法构建训练样本，以过去 48 小时的历史数据作为输入，直接预测未来 24 小时的 AQI 序列。针对每个目标站点单独训练多输出随机森林模型，以更好地适配各站点的局部特征模式。输入特征矩阵首先经过展平处理，将 48 小时  $\times$  30 个特征的二维序列转换为 1440 维的一维特征向量。随后通过标准化和主成分分析（PCA）降维处理，保留 85% 的方差信息。模型采用 MultiOutputRegressor 包装器，构建 50 棵决策树的随机森林集成，每棵树的最大深度限制为 8 层，每次分裂时考虑 50% 的特征，以防止过拟合并提高泛化能力。

如下表 16 为模型的详细参数。

表 16 随机森林多步预测模型的详细参数配置

| 类别    | 参数名称   | 参数值                                          |
|-------|--------|----------------------------------------------|
| 输入/输出 | 历史时间窗口 | 48 小时                                        |
|       | 预测时长   | 24 小时                                        |
|       | 目标站点数  | 5                                            |
|       | 目标站点   | Zuoying, Meinong, Linyuan, Qianjin, Xiaogang |

|        |                        |                            |
|--------|------------------------|----------------------------|
| 随机森林模型 | 基模型                    | RandomForestRegressor      |
|        | 预测策略                   | MultiOutputRegressor（多步预测） |
|        | 树的数量<br>(n_estimators) | 50                         |
|        | 最大深度<br>(max_depth)    | 8                          |
|        | 最小分裂样本数                | 15                         |
|        | 最小叶节点样本数               | 8                          |
|        | 特征选择比例                 | 0.5                        |
| 训练配置   | 优化器                    | 随机森林内置                     |
|        | 数据划分比例                 | 80%训练, 20%测试               |
|        | 随机种子                   | 42                         |
|        | 并行计算                   | 启用 (n_jobs=-1)             |
|        | 早停策略                   | 基于预测误差                     |

如下表 17 展示了随机森林多步预测模型在 Xiaogang、Linyuan、Qianjin、Zuoying、Meinong 5 个空气质量监测站点的整体预测性能，采用 RMSE、MAE、 $R^2$  三个评价指标，全面量化模型在不同站点的预测精度。

总体而言，模型在 5 个站点均表现出稳定的多步预测能力，平均  $R^2$  为 0.6208。Zuoying 站点的预测效果最佳， $R^2$  达到 0.6663，表明模型对该站点的特征模式捕捉最为充分。Xiaogang 站点的  $R^2$  为 0.6342，表现也较为优异。Meinong、Linyuan 和 Qianjin 站点的  $R^2$  分别为 0.6041、0.6034 和 0.5960，虽略低于其他站点，但仍显示出模型具备一定的多步预测能力。所有站点的 RMSE 值在 15.65-19.85 之间，MAE 值在 11.45-14.60 之间，表明模型的预测误差处于合理范围内。

表 17 各站点随机森林模型预测评价指标

| 评价指标  | Xiaogang | Linyuan | Qianjin | Zuoying | Meinong |
|-------|----------|---------|---------|---------|---------|
| RMSE  | 16.5771  | 19.8548 | 18.2381 | 17.8196 | 15.6529 |
| MAE   | 12.5971  | 14.6046 | 13.5078 | 13.3457 | 11.4545 |
| $R^2$ | 0.6342   | 0.6034  | 0.5960  | 0.6663  | 0.6041  |

如下图 26 分别展示了 5 个站点中特定样本的"实际 AQI 值"与"模型预测 AQI 值"的时间序列拟合情况。横轴为"预测时长"对应未来 24 小时预测。从整体趋势来看，各站点样本的预测曲线均能较好地跟随实际曲线的波动规律，体现了随机森林模型捕捉 AQI 时序变化特征的能力。部分样本在峰值或谷值处存在小幅偏差，但整体拟合效果稳定，验证了模型在单个样本上的有效性。




图 26 5 个站点 24 小时 AQI 预测结果拟合对比图

如下表 18 进一步细化了随机森林模型在 4 个不同预测时间段（1-6h、7-12h、13-18h、19-24h）的性能表现。短期预测（1-6h）精度最高，所有站点的  $R^2$  均超过 0.68，其中 Zuoying 站点达到 0.7426，表明模型对近期 6 小时的 AQI 预测能力较强。随着预测时长的增加，模型精度逐渐下降，在 19-24h 时间段，各站点的  $R^2$  普遍降至 0.53-0.62 之间，说明多步预测中存在明显的误差累积效应。不同站点间的性能差异较为明显，Zuoying 和 Xiaogang 站点在各时间段的预测精度相对较高，而 Linyuan 和 Qianjin 站点的长期预测精度相对较低。

表 18 不同时间段不同站点随机森林多步预测评价指标

| 评价指标  | 时间段    | Xiaogang | Linyuan | Qianjin | Zuoying | Meinong |
|-------|--------|----------|---------|---------|---------|---------|
| RMSE  | 1-6h   | 14.6117  | 17.8167 | 15.9716 | 15.6843 | 13.7826 |
| MAE   |        | 1.0124   | 12.8569 | 11.7933 | 11.7072 | 9.9512  |
| $R^2$ |        | 0.7173   | 0.6821  | 0.6916  | 0.7426  | 0.6949  |
| RMSE  | 7-12h  | 16.4994  | 19.7193 | 18.1099 | 17.7382 | 15.3994 |
| MAE   |        | 12.4809  | 14.4269 | 13.3761 | 13.2249 | 11.2583 |
| $R^2$ |        | 0.6401   | 0.6109  | 0.6045  | 0.6717  | 0.6195  |
| RMSE  | 13-18h | 17.328   | 20.5812 | 19.0691 | 18.6158 | 16.3719 |
| MAE   |        | 13.2158  | 15.2301 | 14.1289 | 13.9785 | 12.0291 |
| $R^2$ |        | 0.6026   | 0.5757  | 0.5613  | 0.6382  | 0.5696  |
| RME   | 19-24h | 17.8694  | 21.3018 | 19.8017 | 19.2402 | 17.0576 |

|       |         |         |         |         |         |
|-------|---------|---------|---------|---------|---------|
| MAE   | 13.6792 | 15.9045 | 14.7329 | 14.4721 | 12.5793 |
| $R^2$ | 0.5769  | 0.545   | 0.5265  | 0.613   | 0.5323  |

下图 27 为折线图，清晰展示了 5 个站点在不同预测时间段（1-6h、7-12h、13-18h、19-24h）的  $R^2$  值分布。所有站点的  $R^2$  值均随预测时长的增加呈单调递减趋势：1-6h 时间段  $R^2$  值最高，说明短期预测精度最优；19-24h 时间段  $R^2$  值最低，长期预测因误差累积导致精度明显下降。不同站点间的性能衰减趋势基本一致，但衰减速率存在差异：Zuoying 站点在各时间段的  $R^2$  值均保持较高水平，衰减较为平缓；而 Linyuan 和 Qianjin 站点的  $R^2$  值衰减相对较快，表明模型对这些站点的长期趋势捕捉能力相对较弱。




图 27 不同时间长度  $R^2$  预测效果

### 4.3 Light GBM 模型


LightGBM (Light Gradient Boosting Machine) 是由微软团队于 2017 年提出的一种基于梯度提升决策树 (Gradient Boosting Decision Tree, GBDT) 的高效机器学习框架。它通过基于直方图的决策树算法、叶子生长策略以及并行化与特征并行等技术，在保持高预测精度的同时大幅提升训练速度与内存效率。与传统的梯度提升方法相比，LightGBM 特别适合处理高维度、大样本的时间序列数据，在空气质量预测等时序任务中表现出良好的竞争力。LightGBM 在时间序列预测中具有以下突出优势：

(1) 高效训练与低内存占用：LightGBM 采用直方图算法对特征进行离散化，减少了计算复杂度和内存使用，同时支持并行学习，能够快速处理多变量、长时间跨度的空气质量数据。

(2) 自动特征选择与交互：通过树结构自动进行特征划分与组合，LightGBM 能够有效捕捉变量之间的非线性关系与交互效应，适合处理 AQI 与气象、时空因素之间的复杂依赖。

(3) 鲁棒性与抗过拟合：支持多种正则化手段（如 L1/L2 正则、最大深度控制、叶子节点最小样本数等），配合早停机制和交叉验证，能有效避免过拟合，提升模型泛化能力。

(4) 灵活支持多任务预测：LightGBM 可直接进行多输出回归，适用于多步时间序列预测任务，无需像传统序列模型那样依赖递归结构，从而减少误差累积。



针对空气质量多步预测的核心需求，本研究基于 LightGBM 基础架构进行了针对性改进与场景适配，充分发挥其特征学习与高效训练优势，具体设计如下：

为精准捕捉 AQI 变化的时空动态特征，本研究构建了多层次多维特征集，采用滑动窗口法构建训练样本：以过去 48 小时的历史数据作为输入窗口，预测未来 24 小时的 AQI 连续序列。输入特征体系不仅包含目标站点的核心环境监测数据（PM<sub>2.5</sub>、PM<sub>10</sub>、O<sub>3</sub>、SO<sub>2</sub>、NO<sub>x</sub>、CO、风向、风速等），还融合了四个周边邻近站点的同步监测数据，通过相关性分析确定最优滞后时间，显示建模站点间的空间关联效应。

模型整体采用“特征工程+LightGBM 单模型多输出”的架构设计：首先通过系统化的特征工程挖掘数据价值，再利用 MultiOutputRegressor 包装 LGBMRegressor，构建单模型直接输出 24 维预测结果的预测框架，减少多模型拼接带来的误差传递。具体适配细节有：通过特征工程模块生成时间特征、滞后特征、滚动统计特征、空间聚合特征等多维有效特征，确保输入信息的完整性与针对性；采用 LGBMRegressor 作为基模型，配置 medium 级别正则化平衡拟合能力与泛化能力；通过 MultiOutputRegressor 实现 24 小时预测结果的一次性输出，避免递归预测的误差累积；针对时序数据特性，采用双标准化策略（输入特征 StandardScaler、输出目标 RobustScaler），提升模型训练稳定性；结合早停机制、特征与样本采样策略，进一步增强模型泛化能力，避免过拟合。

如下表 19 为模型的详细参数。

表 19 模型超参数与结构配置

| 类别                | 参数名称               | 参数值                                           |
|-------------------|--------------------|-----------------------------------------------|
| 输入/输出             | 历史时间窗口             | 48 小时                                         |
|                   | 预测时长               | 24 小时                                         |
|                   |                    | 5 个                                           |
|                   | 目标站点数              | (Xiaogang/LinyuanQianjin<br>/Zuoying/Meinong) |
| LightGBM 核<br>心模块 | 基模型                | LGBM Regressor                                |
|                   | 预测策略               | MultiOutputRegressor（单<br>模型多输出）              |
|                   | 提升器类型              | GBDT（梯度提升决策<br>树）                             |
|                   | 正则化级别              | medium                                        |
|                   | 叶子节点数              | 31                                            |
|                   | 最大深度               | 8                                             |
|                   | 最小子样本数             | 20                                            |
|                   | 最小子样本权重            | 1e-2                                          |
|                   | 最小分裂增益             | 0.01                                          |
|                   | L1 正则化系数           | 0.1                                           |
|                   | L2 正则化系数           | 0.1                                           |
|                   | 特征采样比例             | 0.8                                           |
|                   | 样本采样比例             | 0.8                                           |
|                   | 采样频率               | 5                                             |
|                   | 学习率                | 0.05                                          |
|                   | 迭代轮数               | 600                                           |
|                   | 早停轮数               | 50                                            |
| 训练配置              | 数据划分比例             | 训练集 80%、测试集<br>20%                            |
|                   | 输入标准化方法            | StandardScaler                                |
|                   | 输出标准化方法            | RobustScaler                                  |
|                   | 并行计算               | 启用（n_jobs=-1）                                 |
|                   | 随机种子（random_state） | 42                                            |
|                   | 损失函数               | 均方误差（MSE                                      |
|                   | 评估指标               | RMSE、MAE、加权 R <sup>2</sup>                    |

如下表 20 展示了模型在 Xiaogang、Linyuan、Qianjin、Zuoying、Meinong 5 个空气质量监测站点的整体预测性能，采用 RMSE、MAE、R<sup>2</sup> 三个评价指标，全面量化模型在不同站点的

预测精度。

表 20 展示了基于 LightGBM 模型在不同站点的预测性能评估结果。从整体来看，模型在各站点的拟合效果较为稳定， $R^2$  系数介于 0.74 至 0.78 之间，表明模型能够解释大部分数据变异，具备较好的趋势捕捉能力。其中，Meinong 站点的综合表现最优，其 RMSE 和 MAE 均为最低，同时  $R^2$  最高，说明 Meinong 站点与周边邻居站点的环境数据关联度更高，数据环境下模型预测最为准确稳定。Xiaogang 与 Zuoying 站点  $R^2$  也较高，分别达到 0.7631 和 0.7657，表明预测趋势与真实值吻合较好，但 Zuoying 的误差略高，可能存在个别异常波动。相比之下，Linyuan 站点的预测误差最大且  $R^2$  最低，反映出该站点可能存在数据噪声较强或影响因素更为复杂的情况，模型在该处的适应性有待进一步提升。

表 20 各站点 LightGBM 模型预测评价指标

| 评价指标  | Xiaogang | Linyuan | Qianjin | Zuoying | Meinong |
|-------|----------|---------|---------|---------|---------|
| RMSE  | 14.4692  | 17.2093 | 15.7859 | 16.2679 | 12.6501 |
| MAE   | 10.2657  | 11.6168 | 10.9977 | 11.3212 | 8.6153  |
| $R^2$ | 0.7631   | 0.7422  | 0.7490  | 0.7657  | 0.7814  |

图 29 中五张子图展示了每个站点中特定样本的“实际 AQI 值”与“模型预测 AQI 值”的时间序列拟合情况。整体来看，模型能够较好地捕捉 AQI 的时序变化趋势，预测曲线与实际曲线在多数时段内表现出较高的一致性，尤其在波动较为平缓的时段拟合效果良好。具体而言，Xiaogang 和 Meinong 站点的预测曲线与实际曲线重合度较高，反映出模型在这两个站点的预测结果较为准确，与表 2 中较低的 RMSE、MAE 以及较高的  $R^2$  表现相一致。Zuoying 和 Qianjin 站点在整体趋势上吻合较好，但在若干峰值或谷值处存在一定偏差，说明模型对突变响应的捕捉能力仍有提升空间。而在 Linyuan 站点，预测曲线与实际曲线在部分时段差异较为明显，尤其是在 AQI 快速上升或下降阶段，模型未能完全跟上实际变化节奏，这从直观上印证了表 20 中该站点误差最大、拟合度最低的评价结果。




图 29 5 个站点 24 小时 AQI 实际值与预测值拟合对比

表 21 展示了 LightGBM 模型在四个不同预测时间段（1-6h、7-12h、13-18h、19-24h）内，通过通过 RMSE、MAE、 $R^2$  三个指标展示各站点的 AQI 预测性能。整体来看，模型预测精度随预测时长的增加而逐渐下降，表现出明显的时间衰减效应。

具体而言，在 1-6 小时的短期预测中，所有站点的表现均非常出色， $R^2$  普遍高于 0.91，RMSE 和 MAE 也处于最低水平，表明模型在近期预测中具有很高的可信度与稳定性。尤其是 Meinong 站点，其 RMSE 为 6.7371，MAE 为 4.3885， $R^2$  达 0.9277，表现最优。

随着预测时间延长至 7-12 小时，各项指标均出现一定程度的退化， $R^2$  降至 0.72-0.77 之间，RMSE 与 MAE 也相应升高，说明模型对中期趋势的捕捉能力开始减弱。

在 13-18 小时及 19-24 小时的较长期预测中，模型性能进一步下降， $R^2$  普遍介于 0.56-0.67，且误差显著增大。尤其在 19-24 小时时段，各站点  $R^2$  均低于 0.61，反映出模型在应对更长时间跨度的预测时，对波动与复杂模式的拟合能力有限。

从站点差异来看，Meinong 在全部时间段内均保持最佳性能，而 Linyuan 则在多数时段表现相对较弱。

表 21 不同时间段不同站点评价指标

| 评价指标  | 时间段   | Xiaogang | Linyuan | Qianjin | Zuoying | Meinong |
|-------|-------|----------|---------|---------|---------|---------|
| RMSE  |       | 7.8556   | 9.2684  | 8.5219  | 8.5401  | 6.7371  |
| MAE   | 1-6h  | 5.3822   | 5.9390  | 5.6706  | 5.6761  | 4.3885  |
| $R^2$ |       | 0.9189   | 0.9138  | 0.9152  | 0.9245  | 0.9277  |
| RMSE  | 7-12h | 13.6816  | 16.6843 | 15.1288 | 15.2998 | 11.9364 |

|                |        |         |         |         |         |         |
|----------------|--------|---------|---------|---------|---------|---------|
| MAE            |        | 10.0841 | 11.5434 | 10.9794 | 11.0826 | 8.4806  |
| R <sup>2</sup> |        | 0.7537  | 0.7202  | 0.7327  | 0.7577  | 0.7729  |
| RMSE           |        | 16.5111 | 19.6763 | 18.0209 | 18.6155 | 14.4350 |
| MAE            | 13-18h | 12.2805 | 13.9863 | 13.1654 | 13.6366 | 10.3296 |
| R <sup>2</sup> |        | 0.6411  | 0.6103  | 0.6206  | 0.6412  | 0.6676  |
| RMSE           |        | 17.7740 | 20.8138 | 19.2489 | 20.1253 | 15.6161 |
| MAE            | 19-24h | 13.3160 | 14.9985 | 14.1753 | 14.8897 | 11.2625 |
| R <sup>2</sup> |        | 0.5838  | 0.5637  | 0.5671  | 0.5805  | 0.6109  |

如图 30 所示五个站点在不同预测时段的R<sup>2</sup>值变化可以看出，各站点的预测性能均随预测时长的增加呈现明显下降趋势，反映出模型在更长时间跨度下的预测能力逐渐减弱。具体而言，所有站点在 1-6 小时短期预测中R<sup>2</sup>值均处于较高水平（普遍高于 0.9），说明模型在近期预测中具有较好的拟合能力和可靠性。随着预测时段延长至 7-12 小时，各站点R<sup>2</sup>出现一定程度的下降，但仍保持在 0.72-0.77 之间，模型仍具有一定的趋势捕捉能力。进入 13-18 小时及 19-24 小时的长期预测段后，R<sup>2</sup>进一步降低，尤其在 19-24 小时时段，各站点R<sup>2</sup>普遍介于 0.56-0.61 之间，说明模型对较长时间后的 AQI 变化解释能力显著减弱。




图 30 五个站点不同预测时间的 R<sup>2</sup> 值分布

#### 4.4 LSTM 模型

LSTM（Long Short-Term Memory）模型是循环神经网络（RNN）的一种改进变体，由 Hochreiter 和 Schmidhuber 于 1997 年提出，旨在解决传统 RNN 在处理长序列时的梯度消失问

题。与 Transformer 模型不同，LSTM 保留了递归结构，通过引入记忆单元和门控机制（输入门、遗忘门和输出门）来控制信息的流动，从而能够有效捕捉时间序列中的长期依赖关系。

LSTM 在空气质量预测任务中具有以下特点：

（1）时序依赖建模能力：LSTM 能够通过其门控机制学习历史数据中的周期性模式和长期依赖关系，对于空气质量数据中常见的日周期波动和滞后效应具有一定的建模能力。然而，其对长距离依赖的捕捉能力有限，当历史窗口较长（如 48 小时）时，模型性能可能下降。

（2）递归计算限制：由于 LSTM 采用递归结构，其处理序列数据时必须按时间顺序逐步计算，无法像 Transformer 那样对整个时间窗口进行并行处理。这导致 LSTM 在处理较长历史窗口时计算效率较低，训练时间显著增加，特别是在大规模多变量数据集上。

（3）多步预测误差累积：在多步预测任务中，LSTM 通常采用递归预测策略，即每一步的预测结果作为下一步的输入。这种递归机制会导致预测误差的累积，使得长期预测（如 24 小时预测）的准确性下降，特别是在预测时长较长时问题更为明显。

（4）特征提取局限性：LSTM 主要关注时间维度上的依赖关系，对于空间维度上的相关性（如周边站点的空气质量数据）建模能力有限，需要额外设计机制来融合多站点信息，这增加了模型的复杂性。




图 31 LSTM 整体结构

针对空气质量多步预测需求，LSTM 模型做如下适配设计：采用滑动窗口法构建样本，以过去 48 小时的历史数据为输入，预测未来 24 小时 AQI 序列；采用“LSTM 编码器+渐进式全连接解码器”结构，减少多步预测的误差累积。

输入序列  $X \in \mathbb{R}^{B \times 48 \times F}$ （B 为批量大小，F 为特征维度）直接输入模型，通过标准化处理统

一数据分布，无需额外线性嵌入层，保留原始特征的时序关联性。核心编码器由 N=4 层堆叠的 LSTM 单元组成，每层含隐藏状态与细胞状态，通过门控机制动态更新特征；激活函数采用 tanh（细胞状态更新）与 sigmoid（门控开关）组合，平衡特征传递与梯度稳定性。

解码器设计为 LSTM 编码器输出的隐藏特征经展平后，接入多层全连接网络，通过“1024→512→256→24”的渐进式降维，直接回归生成未来 24 小时 AQI 序列；中间层加入层归一化与 Dropout 操作，抑制过拟合。

如下表 22 为模型的详细参数。

表 22 模型超参数与结构配置

| 类别       | 参数名称       | 参数值                        |
|----------|------------|----------------------------|
| 输入 / 输出  | 历史时间窗口     | 48 小时                      |
|          | 预测时长       | 24 小时                      |
| LSTM 模块  | 隐藏层单元数     | 256                        |
|          | 编码器层数 (N)  | 4                          |
|          | dropout 比率 | 0.2                        |
|          | 激活函数       | tanh（细胞状态）、<br>sigmoid（门控） |
| 解码器（全连接） | 隐藏层维度      | [1024, 512, 256]           |
| 训练配置     | 优化器        | AdamW                      |
|          | 初始学习率      | $5 \times 10^{-4}$         |
|          | 权重衰减       | $1 \times 10^{-4}$         |
|          | 学习率策略      | 余弦退火重启                     |
|          | 批量大小       | 64                         |
|          | 最大迭代轮数     | 150                        |
|          | 早停耐心值      | 25                         |

如下表 23 展示了模型在 Xiaogang、Linyuan、Qianjin、Zuoying、Meinong 5 个空气质量监测站点的整体预测性能，采用 RMSE、MAE、R<sup>2</sup>三个评价指标，全面量化模型在不同站点的预测精度。

总体而言，模型在 5 个站点的 R<sup>2</sup> 值均≥0.644，整体具备较强的时序特征拟合能力。Zuoying 站点表现最优，R<sup>2</sup> 达 0.7392，说明模型对该站点 AQI 的时空特征捕捉最充分，预测值与真实值的拟合程度最高，预测稳定性最优；Xiaogang（0.6986）、Meinong（0.6440）站点 R<sup>2</sup> ≥0.69，拟合效果优秀；Qianjin 站点 R<sup>2</sup> 为 0.6780，处于中等偏上水平；Linyuan 站点 R<sup>2</sup> 为 0.6557，是 5 个站点中最低值，反映模型对该站点 AQI 特征的拟合能力相对较弱。LSTM 模型在 5 个监测

站点的 AQI 预测任务中整体表现良好，其中 Zuoying 站点预测精度与稳定性最优，Meinong 站点误差控制效果最佳；而 Linyuan 站点的  $R^2$  最低、RMSE 和 MAE 均为最大值，推测该站点 AQI 波动特征更复杂，模型对其时空特征的捕捉不够充分。

表 23 各站点 LSTM 模型预测评价指标

| 评价指标  | Linyuan | Meinong | Qianjin | Xiaogang | Zuoying |
|-------|---------|---------|---------|----------|---------|
| RMSE  | 18.55   | 14.89   | 16.34   | 15.10    | 15.81   |
| MAE   | 13.01   | 10.62   | 11.66   | 11.02    | 11.34   |
| $R^2$ | 0.6557  | 0.6440  | 0.6780  | 0.6986   | 0.7392  |

如下图 32 至图 36 分别展示了 5 个站点中特定样本的“实际 AQI 值”与“模型预测 AQI 值”的时间序列拟合情况，横轴为“预测时长”对应未来 24 小时预测。从图 32（Xiaogang）、图 33（Linyuan）、图 34（Qianjin）、图 35（Zuoying）、图 36（Meinong）五个监测站点的样本拟合图可见：各站点的预测曲线均能贴合实际 AQI 曲线的波动节奏——无论是 Xiaogang 站点的高频起伏、Linyuan 站点的趋势性变化，还是 Zuoying 等站点的峰谷交替，预测曲线都与实际曲线保持了一致的时序走向，直观体现了 LSTM 模型对 AQI 时序变化特征的捕捉能力。

在部分样本的数值极值区域（如 AQI 峰值或谷值点），预测曲线与实际曲线存在小幅偏差，但此类偏差未脱离整体趋势，且各站点拟合曲线的贴合度均处于较高水平，这进一步验证了 LSTM 模型在单个样本层面的预测稳定性与有效性。




图 32 Xiaogang 某样本拟合图




图 33 Linyuan 某样本拟合图




图 34 Qianjin 某样本拟合图




图 35 Zuoying 某样本拟合图




图 36 Meinong 某样本拟合图

如下表 24 进一步细化了模型在 4 个不同预测时间段（1-6h、7-12h、13-18h、19-24h）的性能表现，通过 RMSE、MAE、 $R^2$  三个指标，揭示模型预测精度随时间长度的变化规律，为模型应用场景（短期/长期预警）提供依据。短期预测精度最高，所有站点的  $R^2$  均 $\geq 0.8$ ，RMSE 和 MAE 均为各时间段最小，这说明模型能精准捕捉 AQI 的短期变化规律，预测可靠性强，可直接用于实时空气质量预警场景。长期预测精度最低，所有站点的 RMSE 和 MAE 均为各时间段最大， $R^2$  普遍降至 0.65 以下，尽管精度较低，但模型仍能捕捉 AQI 的大致趋势，可作为长期空气质量的宏观趋势参考。同时，Linyuan 站点在各时段的 RMSE、MAE 均为所有站点中最高，进一步印证其 AQI 特征复杂度更高，需针对性优化；Meinong 站点则在各时段保持相对最低的误差，预测稳定性更优。

表 24 不同时间段不同站点评价指标

| 评价指标  | 时间段    | Xiaogang | Linyuan | Qianjin | Zuoying | Meinong |
|-------|--------|----------|---------|---------|---------|---------|
| RMSE  | 1-6h   | 10.9115  | 13.9625 | 11.6364 | 10.3178 | 10.7103 |
| MAE   |        | 8.1424   | 9.6777  | 8.3917  | 7.4056  | 7.6785  |
| $R^2$ |        | 0.8428   | 0.8052  | 0.8368  | 0.889   | 0.816   |
| RMSE  | 7-12h  | 14.5972  | 18.4888 | 15.655  | 15.1637 | 14.4016 |
| MAE   |        | 10.7954  | 12.9305 | 11.3387 | 11.1415 | 10.4533 |
| $R^2$ |        | 0.7184   | 0.6581  | 0.7046  | 0.7601  | 0.6673  |
| RMSE  | 13-18h | 16.6955  | 20.3394 | 18.1517 | 17.603  | 16.5678 |
| MAE   |        | 12.2654  | 14.4758 | 13.144  | 12.9457 | 12.0392 |
| $R^2$ |        | 0.6312   | 0.5857  | 0.6025  | 0.6765  | 0.5593  |
| RMSE  | 19-24h | 17.3422  | 20.6302 | 18.9218 | 18.788  | 17.048  |
| MAE   |        | 12.8806  | 14.9668 | 13.7786 | 13.8627 | 12.3002 |
| $R^2$ |        | 0.6015   | 0.5733  | 0.5677  | 0.631   | 0.5329  |

下图 37 为折线图，清晰展示了 5 个站点在不同预测时间段（1-6h、7-12h、13-18h、19-24h）的  $R^2$  值分布，所有站点的  $R^2$  值均随预测时长的增加呈递减趋势：1-6h 时间段  $R^2$  值最高，说明短期预测精度最优；19-24h 时间段  $R^2$  值最低，长期预测因误差累积导致精度下降。不同站点间存在差异：Zuoying 站点在各时间段的  $R^2$  值均相对较高，长期预测（19-24h）仍保持 0.631 的较好水平；Meinong 和 Linyuan 站点的  $R^2$  值整体偏低，长期预测仅为 0.5329 和 0.5733，推测与该站点 AQI 波动更复杂、模型特征捕捉不足有关。该图直观反映了模型在不同预测时长

下的性能衰减规律。




图 37 不同时间长度  $R^2$  预测效果

## 4.5 Transformer 模型

Transformer 模型由 Vaswani 等人于 2017 年首次提出，最初用于解决自然语言处理（NLP）中的序列到序列（Seq2Seq）建模问题。与传统的循环神经网络（RNN）及其变体长短期记忆网络（LSTM）不同，Transformer 完全摒弃了递归结构，转而完全依赖于自注意力机制来捕捉序列中的长距离依赖关系。Transformer 具有以下显著优势，使其在时间序列预测任务中表现出卓越的潜力：

（1）全局感受野与长程依赖捕捉：借助多头自注意力机制，Transformer 能够直接计算序列中任意两个位置之间的关联强度。这意味着模型可以在一步之内捕捉到长达数十甚至数百个时间步之前的历史信息对当前预测的影响，非常适合处理空气质量数据中存在的长周期波动和滞后效应。

（2）高效的并行计算：由于非递归的架构设计，Transformer 允许对整个时间窗口的数据进行并行处理，极大提升了训练效率，使其能够更快速地在大规模多变量数据集上进行迭代优化。

（3）动态特征聚合：注意力机制能够根据当前的上下文环境，动态地赋予不同历史时刻和不同输入变量以不同的权重。这使得模型能够自动筛选出对未来 AQI 变化最为关键的特征，具有很强的可解释性和特征提取能力。




图 38 Transformer 整体结构

本研究基于 Transformer 架构，针对空气质量多步预测的特点进行了改进与适配，以充分利用其强大的时空特征提取能力。为了捕捉空气质量数据的非线性动态变化及复杂的时空依赖关系，本研究构建了多维时空特征集。采用滑动窗口法构建样本，使用过去 48 小时的历史数据作为输入，预测未来 24 小时的 AQI 序列。输入特征不仅包含目标站点的观测数据，还融合了四个周边邻近站点的数据以显式建模空间相关性。本模型采用 Transformer 编码器结合渐进式回归头（Encoder-MLP）的结构，以减少多步预测中的误差累积效应。

输入序列  $X \in \mathbb{R}^{B \times 48 \times F}$  首先通过线性嵌入层映射至高维潜在空间，并加入正弦位置编码以保留时序信息。核心编码器由  $N=3$  层堆叠的 Transformer 块组成。每一层包含 6 头自注意力机制和位置前馈网络（FFN）。为了提升深层网络的训练稳定性，模型采用了 Pre-LN（前置层归一化）结构，并使用 GELU 激活函数代替传统的 ReLU。

为了将编码器提取的潜在特征映射到 24 小时的预测输出，模型设计了一个非自回归的 MLP 解码器。编码器的输出首先被展平，随后通过一系列全连接层进行渐进式降维。每个中间层均包含层归一化、GELU 激活函数及 Dropout 操作，以防止过拟合。该结构能够直接回归生成未来的 24 小时 AQI 序列，避免了递归预测带来的误差传播问题。

如下表 25 为模型的详细参数。

表 25 模型超参数与结构配置

| 类别             | 参数名称                 | 参数值                        |
|----------------|----------------------|----------------------------|
| 输入 / 输出        | 历史时间窗口               | 48 小时                      |
|                | 预测时长                 | 24 小时                      |
| Transformer 模块 | 嵌入维度 ( $d_{model}$ ) | 96                         |
|                | 注意力头数 (H)            | 6                          |
|                | 编码器层数 (N)            | 3                          |
|                | 前馈网络维度               | $384 (4 \times d_{model})$ |
|                | Dropout 比率           | 0.15                       |
|                | 激活函数                 | GELU                       |
| 解码器 (MLP)      | 隐藏层维度                | [1024, 512, 256]           |
| 训练配置           | 优化器                  | AdamW                      |
|                | 初始学习率                | $5 \times 10^{-4}$         |
|                | 权重衰减                 | $1 \times 10^{-4}$         |
|                | 学习率策略                | 余弦退火重启                     |
|                | 批量大小                 | 64                         |
|                | 最大迭代轮数               | 150                        |
|                | 早停耐心值                | 25                         |

如下表 26 展示了模型在 Xiaogang、Linyuan、Qianjin、Zuoying、Meinong 5 个空气质量监测站点的整体预测性能，采用 RMSE、MAE、 $R^2$ 三个评价指标，全面量化模型在不同站点的预测精度。

总体而言模型在 Zuoying 监测站点的预测效果最佳，说明模型对该站点的时空特征捕捉最充分，预测精度和稳定性最优。在 Linyuan 的预测效果较差，说明该站点 AQI 波动可能更复杂，模型对其特征捕捉不够充分。模型在 5 个站点的整体预测效果良好：所有站点  $R^2$  均 $\geq 0.637$ ，其中 Zuoying、Meinong、Xiaogang 3 个站点  $R^2 \geq 0.7$ ，表现优秀；Meinong 站点的误差最小，Linyuan 站点的误差最大，可能需要针对 Linyuan 站点的数据源或特征工程进一步优化。

表 26 各站点 Transformer 模型预测评价指标

| 评价指标  | Xiaogang | Linyuan | Qianjin | Zuoying | Meinong |
|-------|----------|---------|---------|---------|---------|
| RMSE  | 15.3967  | 19.5544 | 16.9243 | 16.7157 | 13.9311 |
| MAE   | 11.0297  | 13.6700 | 11.9451 | 12.3513 | 9.7867  |
| $R^2$ | 0.7109   | 0.6370  | 0.6916  | 0.7382  | 0.7152  |

如下图 39 至 43 分别展示了 5 个站点中特定样本的“实际 AQI 值”与“模型预测 AQI 值”的时间序列拟合情况，横轴为“预测时长”对应未来 24 小时预测，从整体趋势来看，各站点样本的预测曲线均能大致跟随实际曲线的波动规律，体现了模型捕捉 AQI 时序变化特征的能力；部分样本在数值峰值或谷值处存在小幅偏差，但整体拟合效果稳定，验证了模型在单个样

本上的有效性。




图 39 Xiaogang 某样本拟合图




图 40 Linyuan 某样本拟合图




图 41 Qianjin 某样本拟合图




图 42 Zuoying 某样本拟合图




图 43 Meinong 某样本拟合图

如下表 27 进一步细化了模型在 4 个不同预测时间段（1-6h、7-12h、13-18h、19-24h）的性能表现，通过 RMSE、MAE、 $R^2$  三个指标，揭示模型预测精度随时间长度的变化规律，为模型应用场景（短期/长期预警）提供依据。短期预测精度最高，所有站点的  $R^2$  均 $\geq 0.82$ ，RMSE 和 MAE 均为各时间段最小，说明模型对近期 6 小时的 AQI 预测能力极强，能精准捕捉短期变化规律，可用于实时空气质量预警。长期预测精度最低，所有站点的 RMSE 和 MAE 均为各时间段最大， $R^2$  普遍降至 0.66 以下，说明多步预测中的误差累积效应明显，但整体仍保持一定的预测能力，可作为长期空气质量趋势参考。

表 27 不同时间段不同站点评价指标

| 评价指标  | 时间段   | Xiaogang | Linyuan | Qianjin | Zuoying | Meinong |
|-------|-------|----------|---------|---------|---------|---------|
| RMSE  | 1-6h  | 10.6477  | 13.5669 | 12.1079 | 12.2420 | 10.3339 |
| MAE   |       | 7.8853   | 9.4416  | 8.8036  | 9.1481  | 7.5205  |
| $R^2$ |       | 0.8618   | 0.8253  | 0.8421  | 0.8595  | 0.8433  |
| RMSE  | 7-12h | 14.8529  | 18.7647 | 16.3583 | 16.2240 | 13.4561 |
| MAE   |       | 10.7425  | 13.1204 | 11.7106 | 12.0720 | 9.5396  |
| $R^2$ |       | 0.7310   | 0.6658  | 0.7120  | 0.7534  | 0.7344  |

|                |        |         |         |         |         |         |
|----------------|--------|---------|---------|---------|---------|---------|
| RMSE           |        | 16.9732 | 21.7891 | 18.6626 | 18.4092 | 15.1262 |
| MAE            | 13-18h | 12.2962 | 15.5156 | 13.2810 | 13.7314 | 10.5795 |
| R <sup>2</sup> |        | 0.6487  | 0.5493  | 0.6251  | 0.6825  | 0.6643  |
| RMSE           |        | 18.0599 | 22.7717 | 19.5766 | 19.1227 | 16.1134 |
| MAE            | 19-24h | 13.1948 | 16.6023 | 13.9852 | 14.4537 | 11.5073 |
| R <sup>2</sup> |        | 0.6022  | 0.5077  | 0.5874  | 0.6573  | 0.6189  |

下图 44 为折线图，清晰展示了 5 个站点在不同预测时间段（1-6h、7-12h、13-18h、19-24h）的 R<sup>2</sup> 值分布，所有站点的 R<sup>2</sup> 值均随预测时长的增加呈递减趋势：1-6h 时间段 R<sup>2</sup> 值最高，说明短期预测精度最优；19-24h 时间段 R<sup>2</sup> 值最低，长期预测因误差累积导致精度下降。不同站点间存在差异：Zuoying 站点在各时间段的 R<sup>2</sup> 值均相对较高，长期预测（19-24h）仍保持 0.66 的较好水平；Linyuan 站点的 R<sup>2</sup> 值整体偏低，长期预测仅为 0.51，可能与该站点 AQI 波动更复杂有关。该图直观反映了模型在不同预测时长下的性能衰减规律。




图 44 不同时间长度 R<sup>2</sup> 预测效果

## 4.6 模型评估

本次针对台湾省高雄市 Meinong、Zuoying 等五个站点的 AQI 预测拟合中，以 RMSE、MAE 和 R<sup>2</sup> 为核心评估指标。从拟合度 R<sup>2</sup> 来看，Light GBM 模型表现最佳，如下表 28 所示，五个站点的 R<sup>2</sup> 值均在 0.74 以上，显著高于 ARIMA、随机森林等其他模型。该模型的 RMSE 与 MAE 也全区域最低，预测偏差更小，综合来看是最优的 AQI 预测模型。ARIMA 模型拟合度和精度均最差，而随机森林、LSTM 等可作为备选，部分站点表现相对较好。

表 28 不同模型各站点预测评价指标

| 模型             | 评价指标           | Meinong       | Zuoying       | Qianjin       | Xiaogang      | Linyuan       |
|----------------|----------------|---------------|---------------|---------------|---------------|---------------|
| ARIMA 模型       | RMSE           | 19.973        | 22.403        | 19.788        | 19.047        | 22.978        |
|                | MAE            | 12.619        | 15.007        | 13.658        | 12.996        | 15.162        |
|                | R <sup>2</sup> | 0.426         | 0.513         | 0.6179        | 0.5892        | 0.5063        |
| 随机森林模型         | RMSE           | 16.5771       | 19.8548       | 18.2381       | 17.8196       | 15.6529       |
|                | MAE            | 12.5971       | 14.6046       | 13.5078       | 13.3457       | 11.4545       |
|                | R <sup>2</sup> | 0.6342        | 0.6034        | 0.5960        | 0.6663        | 0.6041        |
| Light GBM 模型   | RMSE           | 14.4692       | 17.2093       | 15.7859       | 16.2679       | 12.6501       |
|                | MAE            | 10.2657       | 11.6168       | 10.9977       | 11.3212       | 8.6153        |
|                | R <sup>2</sup> | <b>0.7631</b> | <b>0.7422</b> | <b>0.7490</b> | <b>0.7657</b> | <b>0.7814</b> |
| LSTM 模型        | RMSE           | 18.55         | 14.89         | 16.34         | 15.10         | 15.81         |
|                | MAE            | 13.01         | 10.62         | 11.66         | 11.02         | 11.34         |
|                | R <sup>2</sup> | 0.6557        | 0.6440        | 0.6780        | 0.6986        | 0.7392        |
| Transformer 模型 | RMSE           | 15.3967       | 19.5544       | 16.9243       | 16.7157       | 13.9311       |
|                | MAE            | 11.0297       | 13.6700       | 11.9451       | 12.3513       | 9.7867        |
|                | R <sup>2</sup> | 0.7109        | 0.6370        | 0.6916        | 0.7382        | 0.7152        |

#### 4.7 模型选择与模型改进

由上述 5 个模型的构建结果可以看出 lightGBM 的效果最优，故选择 lightGBM 进行优化。本文基于 Optuna 的超参数进行自动优化，传统的机器学习模型调参方法(网格搜索 Grid Search、随机搜索 Random Search)在高维参数空间中效率较低，且容易陷入局部最优。为提升 LightGBM 多输出回归模型的预测性能，本研究引入了基于贝叶斯优化的自动超参数调优框架 Optuna。

Optuna 是一个开源的超参数优化框架，采用树结构 Parzen 估计器作为采样策略。与传统网格搜索相比，TPE 算法通过构建参数的概率模型，能够更高效地探索参数空间，在较少的试验次数下找到更优的参数组合，如下表 29 展示了各超参数的搜索空间。

表 29 超参数搜索空间

| 超参数               | 搜索范围         |
|-------------------|--------------|
| num_leaves        | [20, 80]     |
| max_depth         | [4, 8]       |
| min_child_samples | [20, 100]    |
| lambda_l1         | [0.001, 3.0] |
| lambda_l2         | [0.001, 3.0] |
| feature_fraction  | [0.5, 0.9]   |
| bagging_fraction  | [0.5, 0.9]   |

|               |              |
|---------------|--------------|
| bagging_freq  | [3, 7]       |
| learning_rate | [0.01, 0.08] |
| n_estimators  | [400, 1500]  |

此外，考虑到本研究为 24 小时多步预测任务，直接优化所有 24 个预测时刻的计算开销较大。因此，本研究采用多时刻加权评估策略，选取第 1、6、12、24 小时作为代表性评估点，并设计加权  $R^2$  作为优化目标：

$$R_{weighted}^2 = \sum_{i=1}^4 w_i \cdot R_{h_i}^2$$

其中， $h_i \in \{1, 6, 12, 24\}$  为评估时刻，权重  $w=[1.5, 1.2, 0.8, 0.5]$  赋予短期预测更高的权重，以平衡短期预测精度与长期预测稳定性。

经过 10 次试验后，Optuna 自动搜索得到的最优超参数如表 30 所示。

表 30 各站点最优参数值

| 参数名称              | Xiaogang | Linyuan | Qianjin | Zuoying | Meinong |
|-------------------|----------|---------|---------|---------|---------|
| num_leaves        | 79       | 67      | 31      | 67      | 21      |
| max_depth         | 7        | 4       | 6       | 4       | 8       |
| min_child_samples | 96       | 20      | 50      | 20      | 87      |
| lambda_l1         | 1.2924   | 0.6846  | 0.5     | 0.6846  | 0.0054  |
| lambda_l2         | 0.1199   | 0.28694 | 0.3     | 0.2869  | 0.0042  |
| feature_fraction  | 0.8687   | 0.7916  | 0.7     | 0.7916  | 0.5733  |
| bagging_fraction  | 0.5353   | 0.8085  | 0.7     | 0.8085  | 0.6216  |
| bagging_freq      | 3        | 3       | 5       | 3       | 5       |
| learning_rate     | 0.0109   | 0.0210  | 0.03    | 0.0210  | 0.0245  |
| n_estimators      | 758      | 527     | 800     | 527     | 720     |

下表 31 展示了优化后 LightGBM 模型在 5 个不同站点（Xiaogang、Linyuan、Qianjin、Zuoying、Meinong）测试集上的预测性能评价指标。与默认参数相比，优化后的模型在各站点的测试集上的加权  $R^2$  均得到了不同程度的提升。在预测精度表现上，Meinong 站点的预测精度最优，其 RMSE（12.8498）和 MAE（8.4852）均为 5 个站点中最低。Linyuan 站点的预测精度相对最弱，RMSE（16.5137）和 MAE（10.9970）均为 5 个站点中最高。在模型拟合效果上，Zuoying 站点的拟合效果最好， $R^2$  达到 0.8105，说明该站点模型能解释约 81.05% 的数据变异。Qianjin 站点的拟合效果相对最差， $R^2$  为 0.7716，但整体仍处于较高的拟合水平。

表 31 各站点优化后 lightGBM 模型预测评价指标

| 评价指标 | Xiaogang | Linyuan | Qianjin | Zuoying | Meinong |
|------|----------|---------|---------|---------|---------|
| RMSE | 14.3052  | 16.5137 | 15.7410 | 15.3864 | 12.8498 |
| MAE  | 9.9389   | 10.9970 | 10.6969 | 10.5586 | 8.4852  |

|                 |        |        |        |        |        |
|-----------------|--------|--------|--------|--------|--------|
| $R^2$           | 0.7866 | 0.7762 | 0.7716 | 0.8105 | 0.7923 |
| $R^2$ 提升<br>(%) | 3.08%  | 4.02%  | 3.02%  | 5.85%  | 1.39%  |

如下图 45 至 49 分别展示了 5 个站点中特定样本的“实际 AQI 值”与“模型预测 AQI 值”的时间序列拟合情况，横轴为“预测时长”对应未来 24 小时预测，从整体趋势来看，各站点样本的预测曲线均能大致跟随实际曲线的波动规律，体现了模型捕捉 AQI 时序变化特征的能力；部分样本在数值峰值或谷值处存在小幅偏差，但整体拟合效果稳定，验证了模型在单个样本上的有效性。




图 45 Xiaogang 某样本拟合图




图 46 Linyuan 某样本拟合图




图 47 Qianjin 某样本拟合图




图 48 Zuoying 某样本拟合图




图 49 Meinong 某样本拟合图

如下表 32 进一步细化了模型在 4 个不同预测时间段（1-6h、7-12h、13-18h、19-24h）的性能表现，通过 RMSE、MAE、 $R^2$  三个指标，揭示模型预测精度随时间长度的变化规律，为模型应用场景（短期/长期预警）提供依据。短期预测精度最高，所有站点的  $R^2$  均 $\geq 0.92$ ，RMSE 和 MAE 均为各时间段最小，说明模型对近期 6 小时的 AQI 预测能力极强，能精准捕捉短期变化规律，可用于实时空气质量预警。长期预测精度最低，所有站点的 RMSE 和 MAE 均为各时间段最大， $R^2$  普遍降至 0.66 以下，说明多步预测中的误差累积效应明显，但整体仍保持一定的预测能力，可作为长期空气质量趋势参考。

表 32 不同时间段不同站点评价指标

| 评价指标 | 时间段 | Xiaogang | Linyuan | Qianjin | Zuoying | Meinong |
|------|-----|----------|---------|---------|---------|---------|
|------|-----|----------|---------|---------|---------|---------|

|                |        |         |         |         |         |         |
|----------------|--------|---------|---------|---------|---------|---------|
| RMSE           |        | 7.5375  | 8.8558  | 8.1709  | 8.0413  | 6.8229  |
| MAE            | 1-6h   | 5.0728  | 5.6084  | 5.2323  | 5.2405  | 4.2998  |
| R <sup>2</sup> |        | 0.9307  | 0.9255  | 0.9281  | 0.9394  | 0.9317  |
| RMSE           |        | 13.4287 | 15.9579 | 14.9850 | 14.4396 | 12.1368 |
| MAE            | 7-12h  | 9.6842  | 10.9167 | 10.5666 | 10.2794 | 8.3501  |
| R <sup>2</sup> |        | 0.7801  | 0.7583  | 0.7583  | 0.8047  | 0.7839  |
| RMSE           |        | 16.3995 | 18.9244 | 17.9698 | 17.6303 | 14.7142 |
| MAE            | 13-18h | 11.9681 | 13.2513 | 12.9113 | 12.7692 | 10.1888 |
| R <sup>2</sup> |        | 0.6720  | 0.6600  | 0.6524  | 0.7088  | 0.6823  |
| RMSE           |        | 17.6768 | 19.9900 | 19.4137 | 19.0519 | 15.8149 |
| MAE            | 19-24h | 13.0305 | 14.2118 | 14.0773 | 13.9453 | 11.1022 |
| R <sup>2</sup> |        | 0.6189  | 0.6206  | 0.5942  | 0.6599  | 0.6329  |

下图 50 为折线图，清晰展示了 5 个站点在不同预测时间段（1-6h、7-12h、13-18h、19-24h）的  $R^2$  值分布，所有站点的  $R^2$  值均随预测时长的增加呈递减趋势：1-6h 时间段  $R^2$  值最高，说明短期预测精度最优；19-24h 时间段  $R^2$  值最低，长期预测因误差累积导致精度下降。不同站点间存在差异：Zuoying 站点在各时间段的  $R^2$  值均相对较高，长期预测（19-24h）仍保持 0.65 的较好水平；Qianjin 站点的  $R^2$  值整体偏低，长期预测仅为 0.59，可能与该站点 AQI 波动更复杂有关。该图直观反映了模型在不同预测时长下的性能衰减规律。




图 50 不同时间长度  $R^2$  预测效果

## 五、建模结果解释

### 5.1 Xiaogang 建模结构解释

尽管先前构建的 lightGBM 模型在 AQI 预测任务上展现了优异的性能，但其内在的复杂性和集成树结构使其本质上成为一个“黑箱”模型，仅仅获得高精度的预测结果是远远不够的。理解模型“为何”做出特定预测，即模型的可解释性，对于建立临床信任、验证模型决策逻辑的可靠性、以及发掘潜在的生物学或行为学关联至关重要。为了打开这一“黑箱”，本文引入了基于博弈论的 SHAP 框架进行事后可解释性分析。SHAP 是一种先进的、模型无关的解释方法，它通过计算每个特征对单次预测的贡献度，能够提供坚实理论基础支持下的全局可解释性和局部可解释性。全局层面，我们可以识别出对整体模型影响最大的关键特征；局部层面，我们可以深入剖析对于每一个具体样本，模型是如何权衡各项指标最终得出其患病风险预测的。

如下图 51 的 Xiaogang-SHAP 摘要图提供了模型决策的宏观视角，揭示了哪些特征对预测结果的贡献最大，以及这些特征如何影响预测方向。图中越靠上的特征，对模型预测的整体影响越大。最顶部的 neighbor\_AQI\_mean\_t-1 是对模型影响最大的特征，而最底部的 AQI\_t-2 影响最小。neighbor\_AQI\_mean\_t-1 特是影响模型预测结果的最重要特征，该特征呈现出明显的正相关性：当其取值较高（红色点）时，其 SHAP 值集中在正方向，表明邻近区域较高的 AQI 均值会显著推高模型的预测结果；反之，当取值较低（蓝色点）时，其 SHAP 值向负方向偏移，拉低预测结果。对于 AQI\_t-1 和 Qianjin\_PM2.5\_t-1，该特征同样表现出强烈的正向自相关性，也是高度重要的特征，其高取值对预测结果具有显著的正向推动作用。这些结果共同揭示了模型对 AQI 预测的强依赖性：它主要基于时间上的自相关性和空间上的邻域相关性，尤其是关键污染物 PM<sub>2.5</sub> 的浓度。




图 51 Xiaogang-SHAP 摘要图

为了深入探究特征如何具体影响模型输出，并观察它们之间的交互作用，图 52 展示了关键特征依赖性与交互效应分析，如图 52（A）展示了  $\text{neighbor\_AQI\_mean\_t-1}$  取值较低（小于 0）时，其 SHAP 值迅速从负值上升到接近 0。当取值较高（大于 0.5）时，SHAP 值呈稳定上升趋势，高取值对预测结果具有显著的正向推动作用。在  $\text{neighbor\_AQI\_mean\_t-1}$  的低取值区域，深蓝色点（低 AQI 滚动均值）对应更负的 SHAP 值，高取值区域，高 AQI 滚动均值对应更高的 SHAP 值。邻居 AQI 均值与 AQI 滚动均值之间存在正向增强的交互作用。当两者都高时，对预测结果的推高作用会进一步增强。图 52（B）展示了图形呈现出清晰的线性关系，斜率大致稳定。AQI\_t-1 的取值越高，其 SHAP 值越高，表明前一时段 AQI 对当前预测具有强烈的正向自相关性。AQI\_t-1 与 AQI\_t-2 存在显著的正向交互作用。如图 52（C）呈现出 Qianjin\_PM2.5\_t-1 非线性、指数增长的趋势，在低取值区域，SHAP 值变化平缓且多为负值；而 Qianjin\_PM2.5\_t-1 超过一定阈值，SHAP 值急剧上升。这表明前金的 PM2.5 浓度只有达到较高水平后，才会对 AQI 预测产生显著的(正向)影响。Qianjin\_PM2.5\_t-1 与  $\text{neighbor\_AQI\_mean\_t-1}$  存在正向交互作用。当前金 PM2.5 高时，如果邻居 AQI 也高，对预测的推高作用更大。如图 52（D）PM2.5\_t-1 呈非线性上升趋势，但曲线更为分散。PM2.5\_t-1 的高取值同样对预测结果产生显著的正向贡献。PM2.5\_t-1 与  $\text{AQI\_lag\_1\_t-1}$  之间存在正向交互作用，进一步增强了 PM2.5 对 AQI 预测的贡献。




图 52 Xiaogang-关键特征依赖性与交互效应分析

如下图 53 是 Xiaogang 站点“未来 1 小时 AQI 预测”的 SHAP 瀑布图，用于解释单个样

本的预测结果是如何由各特征共同作用得到的。图中蓝色条代表特征对预测结果的负向贡献（拉低预测值），红色条代表正向贡献（推高预测值），条的长度对应贡献强度。AQI\_t-1（前 1 小时 AQI）的 SHAP 值为-0.13，是影响该样本预测结果的核心因素，直接将预测值从全局均值向更低水平拉动，这与“历史 AQI 是短期空气质量预测的关键先验信息”的认知一致。AQI\_t-2（前 2 小时 AQI）、neighbor\_AQI\_mean\_t-1（邻站 AQI 均值）、Qianjin\_PM2.5\_t-1（前 1 小时 Qianjin 站点 PM<sub>2.5</sub>）等特征的 SHAP 值均为-0.01，进一步协同拉低预测结果，体现了多源污染物、多站点信息对 AQI 预测的联合约束作用。PM<sub>2.5</sub>\_t-3（前 3 小时 PM<sub>2.5</sub>）、PM<sub>2.5</sub>\_t-1（前 1 小时 PM<sub>2.5</sub>）的 SHAP 值为+0.01，对预测结果存在轻微的正向拉动，但贡献强度远低于负向特征，未改变预测值低于全局均值的趋势。在 Xiaogang 站点中，历史 AQI 的滞后信息是主导未来 1 小时 AQI 预测结果的核心特征，邻站污染物、同期 PM<sub>2.5</sub> 等特征通过协同作用进一步强化了预测结果的变化趋势，验证了模型对多源时序特征的有效捕捉能力。




图 53 Xiaogang-未来一小时 AQI 预测瀑布图

## 5.2 linyuan 建模结构解释

该图 54 显示了 Linyuan 站点特征重要性排序，整体模式与 Xiaogang 相似，但特征权重分布略有差异。neighbor\_AQI\_mean\_t-1 仍为最重要特征，AQI\_t-1 与本地 PM<sub>2.5</sub> 滞后项也居前列，说明该站点同样依赖时空滞后信息。




图 54 Linyuan-SHAP 摘要图

依赖图 55 表明，Linyuan 站点中 neighbor\_AQI\_mean\_t-1 与 AQI\_t-1 对预测的影响接近线性正相关，且两者之间存在明显的正向交互。PM<sub>2.5</sub> 相关特征的影响曲线较为平滑，未出现剧烈阈值效应。




图 55 Linyuan-关键特征依赖性与交互效应分析

针对 Linyuan 站点某一样本，瀑布图 56 显示 AQI\_t-1 与 neighbor\_AQI\_mean\_t-1 为主要负向贡献特征，共同将预测值拉低。其余特征贡献较小，整体解释模式与 Xiaogang 站点类似，进一步验证了模型决策逻辑的一致性。




图 56 Linyuan-未来一小时 AQI 预测瀑布图

### 5.3 Qianjin 建模结构解释

如下图 57，在该站点中，Qianjin\_PM<sub>2.5</sub>\_t-1 成为最重要的特征，其 SHAP 值分布范围广且正影响显著，突显了本地 PM<sub>2.5</sub> 浓度对 AQI 预测的主导作用。邻站 AQI 均值与历史 AQI 仍是重要辅助特征。




图 57 Qianjin-SHAP 摘要图

图 58 中 Qianjin\_PM<sub>2.5</sub>\_t-1 表现出明显的非线性影响：低浓度区间 SHAP 值平缓且多为负值，浓度超过约 1.0 后 SHAP 值快速上升。该特征与 neighbor\_AQI\_mean\_t-1 存在协同增强效应，说明在高污染情境下空间与本地污染指标共同推高预测结果。




图 58 Qianjin-关键特征依赖性与交互效应分析

该样本解释显示，Qianjin\_PM<sub>2.5</sub>\_t-1 为最大正向贡献特征，显著推高预测值；历史 AQI 特征则提供负向调整。各特征贡献方向不一，体现出该站点预测中污染物浓度与历史趋势之间的复杂权衡。




图 59 Qianjin-未来一小时 AQI 预测瀑布图

### 5.4 Zuoying 建模结构解释

Zuoying 站点的特征重要性分布较为均衡，前几位特征包括 neighbor\_AQI\_mean\_t-1、AQI\_t-1 及多个 PM<sub>2.5</sub>滞后项，说明模型综合运用时空与多污染物信息进行预测，结构相对稳健。




图 60 Zuoying-SHAP 摘要图

依赖关系图 61 显示，各主要特征与 SHAP 值之间均呈现清晰的正相关趋势，且交互效应普遍为正向增强型。特征间协同作用明显，可能与本站点数据质量较高、模式清晰有关。




图 61 Zuoying-关键特征依赖性与交互效应分析

瀑布图 62 解释显示，各特征贡献方向一致为正，共同将预测值推高。AQI\_t-1 与 neighbor\_AQI\_mean\_t-1 贡献最大，说明历史 AQI 与空间关联仍是本站点预测的核心依据。




图 62 Zuoying-未来一小时 AQI 预测瀑布图

## 5.5 Meinong 建模结构解释

该摘要图 63 中，AQI\_t-1 的重要性超过 neighbor\_AQI\_mean\_t-1 居首位，表明本站点预测更依赖自身历史 AQI 序列。PM<sub>2.5</sub> 相关特征影响相对较弱，可能与该站点污染结构相对简单有关。




图 63 Meinong-SHAP 摘要图

依赖图 64 显示，AQI\_t-1 与 SHAP 值呈强线性正相关；PM<sub>2.5</sub>\_t-1 的影响则呈现轻度非线性，在中等浓度以上贡献增强。特征间交互效应较弱，模型决策模式相对简单。




图 64 Meinong-关键特征依赖性与交互效应分析

该样本解释中，AQI\_t-1 为主要正向贡献特征，其余特征影响较小且方向不一。整体预测结果接近基准值，反映出模型在该站点预测中的平稳性与可解释性。




图 65 Meinong-未来一小时 AQI 预测瀑布图

## 六、结论与展望

### 6.1 结论

本研究以台湾省高雄市 2020-2024 年五个典型监测站点的小时级空气质量数据为基础，围绕非平稳背景下的 AQI 预测问题，构建了涵盖传统时序模型、机器学习模型与深度学习模型的多算法对比体系，结合系统的特征工程与可解释性分析，得出以下核心结论：

（1）数据特征与污染格局方面，高雄市空气质量呈现显著的时空异质性与周期性特征。空间上形成“南高北低”格局，林园、小港等工业区站点污染浓度显著高于美浓山区站点；时间上表现为“冬高夏低”的 U 型规律，冬季以颗粒物（PM<sub>2.5</sub>、PM<sub>10</sub>）为主要污染物，夏季臭氧（O<sub>3</sub>）占比上升，且 2020 年后污染物浓度整体呈下降趋势，仅臭氧略有上升。

（2）特征工程有效性方面，构建的“时间-风场-滞后-滚动统计-邻居聚合”多维特征体系，充分融合了污染演变的物理机制与统计规律，为模型提供了丰富的信息支撑。其中，PM<sub>2.5</sub>滞后特征、邻居站点 AQI 均值、历史 AQI 时序特征成为影响预测结果的核心因子，验证了污染累积效应与空间传输效应的重要性。

（3）模型性能对比方面，LightGBM 模型在全站点、全时段的预测中表现最优。其五个站点的 R<sup>2</sup> 值均在 0.74 以上，Linyuan 站点更是达到 0.7814，且 RMSE 与 MAE 指标均为最低，展现出强大的拟合能力与误差控制能力；Transformer 与 LSTM 模型在捕捉长时依赖方面表现

尚可，但整体精度不及 LightGBM；随机森林模型性能稳定但拟合度有限；ARIMA 模型难以适配非线性与非平稳数据，预测效果最差( $R^2$  多低于 0.6)。经 Optuna 超参数优化后 LightGBM 模型的  $R^2$  进一步提升 3%-6%，预测稳定性显著增强。

(4) 模型可解释性方面，SHAP 分析揭示了不同站点的预测逻辑差异：前金站点受本地  $PM_{2.5}$  浓度影响最大，美浓站点更依赖自身历史 AQI 序列，而小港、左营等站点则表现出时空特征协同作用的显著影响。整体来看，历史污染状态与区域污染背景是所有站点预测的核心依据，符合大气污染演变的物理规律。

## 6.2 展望

基于本研究的成果与局限，未来可从以下方向进一步深化与拓展：

(1) 模型优化方面，可探索模型融合策略，将 LightGBM 的强拟合能力与 Transformer 的长时依赖捕捉优势相结合，构建混合预测模型，提升极端污染事件的预测精度；同时引入注意力机制与时空卷积模块，进一步强化对污染时空传输过程的建模能力。

(2) 特征拓展方面，可纳入更多维度的影响因子，如气象预报数据（温度、湿度、气压）、污染源排放清单、交通流量实时数据等，丰富特征体系的物理内涵；此外，可尝试引入遥感反演的区域污染数据，提升对大范围污染传输效应的刻画精度。

(3) 应用场景延伸方面，可将模型从 24 小时短期预测拓展至 7 天中长期趋势预测，为区域空气质量管控提供更具前瞻性的决策支持；同时开发针对性的预警阈值体系，结合不同站点的污染特征，制定差异化的应急响应策略，提升模型的实用价值。

(4) 研究范围拓展方面，可将本研究的方法体系推广至台湾其他城市或东亚同类型工业港口城市，验证模型的泛化能力；同时可延长时间序列跨度，纳入更多突发公共卫生事件或极端气象事件的影响样本，进一步强化模型在非平稳场景下的鲁棒性。

(5) 可解释性深化方面，可结合大气化学传输模型的模拟结果，构建“数据驱动+机理建模”的联合解释框架，不仅明确“哪些因素影响预测”，更能揭示“污染如何演变”的内在机制，为精准施策提供更深入的科学支撑。

## 七、参考文献

- [1] 裴飞扬,王建成,孟醉,等.机器学习在大气污染预测与溯源方面的应用进展[J/OL].环境化学,1-16[2025-11-30].
- [2] 魏佳芳,魏荣升,赵天赐,等.基于 XGBoost 与 SHAP 的绵阳空气质量预测与因素分析[J/OL].安全与环境学报,1-9[2025-11-30].
- [3] 秦杨,翟帅,石博文,等.基于机器学习的东北地区平原型城市空气质量重度污染预测模型构

- 建——以吉林省白城市为例[J].地理科学,2025,45(08):1720-1732.
- [4] 朱效锋,张倩,朱小平.基于机器学习的城市空气质量预测模型分析[J].现代信息科技,2025,9(10):17-22.
- [5] 金长宇,于佳强,王强,等.基于集成学习 CatBoost 优化模型的爆堆大块率预测[J].东北大学学报(自然科学版),2023,44(12):1743-1750.
- [6] 吕红燕,冯倩.随机森林算法研究综述[J].河北省科学院学报,2019,36(03):37-41.
- [7] 杨剑锋,乔佩蕊,李永梅,等.机器学习分类问题及算法研究综述[J].统计与决策,2019,35(06):36-40.
- [8] 涂佩玥,杨欢,陈兰洲,等.中国重点城市大气污染与健康风险的时空分布特征[J].环境科学,2023,44(11):5954-5963.
- [9] Karmoude M ,Munhungewarwa B ,Chiraira I , et al.Machine learning for air quality prediction and data analysis: Review on recent advancements, challenges, and outlooks[J].Science of the Total Environment,2025,1002180593-180593.
- [10] Iqbal A ,Mukherjee N .A Systematic Review and Comparative Study of Machine Learning Techniques for Air Quality Prediction[J].Water, Air, & Soil Pollution,2025,236(12):789-789.
- [11] Muralikrishnan R ,Gollapalli S ,Sellappan E , et al.Machine learning-driven prediction and interpretation of air quality index in industrial environment[J].Asian Journal of Civil Engineering,2025,(prepublish):1-19.
- [12] Muhammad A ,Tabasam R ,Asif A .Fermatean fuzzy multi-criteria decision-making based on Spearman rank correlation coefficient[J].Granular Computing,2023,8(6):2005-2019.
- [13] Amjad M A ,Sigurdur E ,Leif S , et al.Predicting Pavement Condition Index Using an ML Approach for a Municipal Street Network[J].Journal of Transportation Engineering, Part B: Pavements,2025,151(2):
- [14] He X ,Zhang S ,Bai Q , et al.Air pollution exposure and prevalence of non-alcoholic fatty liver disease and related cirrhosis: A systematic review and meta-analysis.[J].Ecotoxicology and environmental safety,2024,289117469.