

个人角色与工作内容

在本次多维度特征下糖尿病分类模型构建及可解释性分析项目中，我担任数据与模型核心执行者，完成全流程工作。

主要工作：

1. 完成数据清洗、预处理与标准化，保障数据质量。
2. 开展探索性数据分析与可视化，挖掘糖尿病关键风险特征。
3. 完成人群聚类分析，实现健康风险分层。
4. 搭建并优化多种机器学习分类模型，完成模型训练与性能评估。
5. 开展模型可解释性分析，解读特征贡献与决策逻辑。
6. 整理分析结果，完成论文撰写与成果呈现。

多维度特征下糖尿病分类模型构建及可解释性分析

摘要

糖尿病作为一种多因素耦合的复杂慢性疾病，其早期筛查对于降低公共卫生负担至关重要。针对传统侵入性检测成本高、普及难的问题，本研究旨在利用美国疾病控制与预防中心（CDC）的非侵入性健康指标数据，构建高效的机器学习分类模型，以实现糖尿病患病风险的精准预测与致病机制解析。本研究纳入了包含人口统计、生活方式及健康病史在内的 25 万 3680 条多维数据，经清洗与预处理后，首先采用 K-Means 无监督聚类算法探索样本的潜在亚群结构。随后，针对数据类别不平衡问题，系统构建并比较了 Logistic 回归、随机森林和 XGBoost 三种机器学习分类模型；最后，应用 SHAP 博弈论框架对模型进行全局与局部可解释性分析，以揭示特征贡献度及交互效应。

聚类分析显示，样本在 $K=2$ 时轮廓系数达到最优，人群可划分为“健康/低风险”与“亚健康/高风险”两类亚群。模型对比结果表明，XGBoost 模型在测试集上表现优异，AUC 值达到 0.8201，召回率为 0.7677，表明模型具备良好的疾病识别与区分能力，能有效减少漏诊。SHAP 分析揭示总体健康状况、年龄、BMI、高血压及高胆固醇是影响糖尿病风险的前五大关键因子，且年龄与 BMI 之间存在显著的正向交互增强效应。本研究构建的 XGBoost 模型结合 SHAP 可解释性分析，不仅提供了一种高精度的非侵入性糖尿病筛查工具，还成功量化了各风险因素的边际贡献。该模型有助于医疗机构快速识别高危人群，并为制定个性化的干预策略提供了强有力的数据驱动支持。

目 录

一、 引言	1
1.1 数据集背景	1
1.2 研究动机与目的	1
1.3 国内外文献综述	2
二、 数据描述与预处理	3
三、 探索性数据分析	5
3.1 单变量分析	5
3.2 多变量分析	9
四、 聚类分析	14
五、 糖尿病分类预测模型构建	17
5.1 Logistic 模型	17
5.2 随机森林模型	18
5.3 XGBoost 模型	20
六、 基于 SHAP 的模型可解释性分析	23
七、 总结与展望	28
1.总结	28
2.展望	29
参考文献	30

一、引言

1.1 数据集背景

本文旨在基于多种健康指标构建机器学习模型，对个体进行糖尿病与否的分类。本研究采用的数据集源自美国疾病控制与预防中心（CDC）主导的年度健康调查项目。作为全球最大的持续性健康调查系统之一，该数据集从全美各州收集了数十万份关于美国居民健康相关风险行为、慢性健康状况以及预防性服务使用情况的真实世界数据。数据集系统整合了人口统计、生活方式及健康风险因素等多个核心健康维度，为糖尿病疾病进展机制解析与预防干预策略制定提供了强有力的数据驱动支撑。研究的核心目标变量为是否患有糖尿病，为了构建二分类预测模型，0 代表受访者未患有糖尿病，1 代表受访者已被确诊患有糖尿病。通过多维特征的建模与分析，可以全面评估个体糖尿病风险因素，并为疾病预警和个性化干预策略提供科学依据。

1.2 研究动机与目的

糖尿病作为全球高发的慢性代谢性疾病，其高患病率、高并发症率及高管理成本已成为重大公共卫生挑战。尽管现有研究已证实遗传易感性、生活方式及临床指标与糖尿病发病及进展密切相关，但各因素间的交互作用机制尚未完全明晰，且缺乏基于多维度数据的精准风险预测与干预靶点识别模型。传统的糖尿病诊断主要依赖于空腹血糖或糖化血红蛋白等侵入性临床检测。然而，这些手段往往需要专业的医疗设备和医护人员参与，难以在大规模人群中进行高频次的普查，导致大量潜在患者或早期患者漏诊。相比之下，基于人口统计学特征、生活方式及基础健康指标的非侵入性风险评估模型，具有低成本、高便捷性的优势。本研究利用 CDC 数据构建模型，正是为了探索一种更高效的初筛手段。糖尿病是一种多因素耦合的复杂代谢性疾病，其发病并非单一因素作用的结果，而是遗传背景、环境暴露、行为习惯等多维变量非线性交互的产物。传统的统计学方法在处理高维数据和捕捉变量间复杂的非线性关系时往往力不从心。引入机器学习算法，能够更精准地从海量数据中提取特征模式，识别出传统方法难以发现的隐性风险组合，从而显著提高预测的准确性和鲁棒性。

基于上述动机,本研究的核心目标是构建一个具有高灵敏度和特异性的二分类模型,实现对个体患病状态的精准预测,并解决数据不平衡可能带来的预测偏差问题。通过模型的可解释性分析,量化不同变量对糖尿病发病的贡献度。这将有助于揭示各风险因素间的交互作用机制,为病因学研究提供数据支持。研究成果可转化为简易的自我筛查工具,帮助普通民众通过输入基础生活指标即可快速评估自身风险,从而通过改变生活方式来逆转或延缓疾病进程。

1.3 国内外文献综述

在糖尿病预测领域,算法的选择直接决定了筛查的效能。张占林和孙勇^[1] (2021) 针对体检人群的糖尿病风险预测进行了实证研究,结果表明,相比于传统的 Logistic 回归模型,随机森林算法在处理体检大数据时表现出更高的预测价值,能够更准确地识别潜在的高危人群,这证实了集成学习方法在处理非线性医疗数据方面的天然优势。在此基础上,覃伟和高敏^[2] (2020) 进一步探讨了多种机器学习算法在糖尿病相关指标预测中的应用,通过对比不同模型的拟合效果,验证了机器学习在捕捉复杂生理参数波动方面的鲁棒性。然而,尽管随机森林通过 Bagging 策略降低了方差,但基于 Boosting 策略的 XGBoost 在处理稀疏数据和防止过拟合方面表现更为卓越。Hasan 等^[3] (2020) 指出,针对高维调查数据,科学的特征工程是提升模型泛化能力的前提。然而真实世界的医疗数据普遍存在“类别不平衡”问题。Krawczyk^[4] (2016) 综述指出,直接使用不平衡数据训练会导致分类器偏向多数类,从而增加漏诊率。因此,Akiba T 等^[5] (2019) 结合重采样技术或利用自动化框架 Optuna 进行针对性的超参数寻优,是构建鲁棒模型的必要步骤。尽管集成学习模型在精度上表现优异,但其复杂的“黑盒”结构导致模型缺乏类似于 LR 回归系数的直观解释性,限制了其在临床辅助决策中的应用。为了解决这一矛盾,Lundberg 和 Lee^[6] (2017) 提出了基于合作博弈论的 SHAP 框架。该方法不仅能像逻辑回归一样给出特征的正负贡献方向,还能通过可视化手段揭示特征间的非线性交互效应。这种“高精度+强解释”的建模范式,正逐渐成为医学人工智能研究的标准。

综上所述,现有研究已证实了机器学习算法相较于传统统计学方法的优势,但在处理大规模非侵入性数据的类别不平衡问题,以及对模型内部致病机制的深

层解析方面仍有待深化。鉴于此，本研究拟利用 CDC 大数据，首先通过 K-Means 聚类探索样本结构，采用 Optuna 框架优化 XGBoost 模型以解决不平衡与过拟合问题，最后结合 SHAP 框架进行多维度的可解释性分析，旨在构建一个兼具逻辑回归的可解释性与深度模型高精度的糖尿病筛查系统。

二、数据描述与预处理

该糖尿病数据集共 25 万 3680 条数据，数据包含 22 个指标，其中，连续数值型特征有 1 个，二分类特征有 15 个，有序分类特征有 6 个。其中，MentHlth 表示在过去 30 天中有心理健康问题的天数，PhysHlth 表示在过去 30 天中有身体健康问题的天数。数据集特征如下表 1 所示：

表 1 数据集特征

特征类别	指标名称	数据类型	中文释义
人口统计学特征	Sex	二分类	性别
	Age	有序分类	年龄
	Education	有序分类	受教育水平
	Income	有序分类	收入
生活方式相关	PhysActivity	二分类	体育活动
	Fruits	二分类	水果摄入
	Veggies	二分类	蔬菜摄入
	HvyAlcoholConsump	二分类	大量饮酒
健康风险因素	HighBP	二分类	高血压状态
	HighChol	二分类	高胆固醇状态
	CholCheck	二分类	胆固醇检查史
	BMI	连续值	体重指数
	Smoker	二分类	吸烟状态
	Stroke	二分类	中风史
医疗资源 与健康认知	HeartDiseaseorAttack	二分类	心脏疾病史
	DiffWalk	二分类	行动困难
	AnyHealthcare	二分类	医疗保障
	NoDocbcCost	二分类	因费用问题未看医生

	GenHlth	有序分类	总体健康状况
	MentHlth	有序分类	心理健康状况
	PhysHlth	有序分类	身体健康状况
目标变量	Diabetes_binary	二分类	是否患糖尿病

在糖尿病健康数据集的预处理环节，针对缺失值、重复值与异常值的处理需结合医学场景的特殊性进行科学决策。对于缺失值与重复值，本研究通过数据探查确认无缺失值，这为后续分析奠定了数据完整性基础。对于重复值如下图 1，去除重值 24206 条后的前后数据量的对比。对于异常值，如下图 2 对数值型变量 BMI 使用了箱线图进行异常值检测，样本量为 22 万 9474 条，异常值存在 5638 条，占 2.5%。但是考虑到糖尿病数据的医学属性，有时异常值并非数据噪声，而是可能反映极端健康状态的关键信息，故本研究对异常值予以保留。这些极端值可作为揭示病理特征、挖掘高危人群异质性的重要线索，因为该数据集来源于美国人口，根据美国疾病控制与预防中心（CDC）及相关医学文献的定义，BMI > 40 被归类为 III 级肥胖，而 BMI > 50 甚至更高在医学上被称为“极重度肥胖”。鉴于美国肥胖率的流行现状，高达 90 的 BMI 数值虽然极端，但在生理学上是可信的，属于真实的极端表型而非测量误差。这部分高 BMI 人群往往是糖尿病的高风险群体，包含着预测模型所需的关键“强信号”。直接剔除这部分长尾数据将人为引入截断偏差，导致模型无法学习到极端肥胖与糖尿病之间的非线性关联，从而显著降低模型在真实世界高危人群中的泛化能力。




图 1 重复值去除前后的对比




图 2 BMI 分布及异常值

标准化处理是数据预处理中的重要一环，旨在消除不同量纲和取值范围对建模结果的影响。经过数据清洗和标准化的预处理操作，原始健康数据已具备较高质量和一致性，能够有效支撑后续模型构建工作。有效的预处理流程不仅提升了模型的泛化能力，还为后续挖掘数据潜在规律及实现个性化糖尿病风险预测奠定了坚实基础。

三、探索性数据分析

3.1 单变量分析

本节将针对数据集中关键变量的统计特性进行详细探讨，使用直方图、箱线图等统计图来探索每个变量的分布情况。通过这些分析，我们旨在全面了解每个变量的基本情况，确保数据的质量和有效性，并为后续的多变量分析和建模工作提供初步指导。如下图 3，展示了否患病的分布柱形图，已诊断为糖尿病的占比为 15.3%，未诊断为糖尿病的占比约为 84.7%，非糖尿病群体的数量远多于糖尿病群体。




图 3 是否患糖尿病人数分布

如下图 4 是对基本人口学特征进行了详细分析，主要涉及性别、年龄、教育水平及收入等关键变量。图 4（A）中显示了女性和男性的比例：女性占比 56.1%，男性占比 43.9%。该分布接近 1:1，性别在样本中比较均衡，说明样本具有良好的代表性，不存在明显的性别偏倚。图 4（B）中显示了年龄分布，年龄分布从 1（18-24 岁）到 13（80 岁及以上）共 13 个类别。可以发现随着年龄的增长，样本数量呈现先逐渐增加后减少的趋势，尤其是 7 到 11 组，即 50 岁至 75 岁的人数相对较多。该疾病主要关注中老年群体，这个群体的健康管理需求较大。图 4（C）显示了教育水平分布，约 94% 的样本是大学就读过但无学位（Level 4 及以上），未完成高中教育的比例极低（0.1%），这说明样本中的个体受教育水平普遍较高，可能受教育水平较高的人群更倾向于关注和管理自身健康。图 4（D）显示了收入分布，收入较低（1-4）的群体约占 30%，这些人群的收入较低；中高收入（5-8）的群体随着收入水平的提高，样本中的比例逐步增加。最高收入组占 31.3%，为收入分布的顶端。收入水平的分布表明存在较大的收入差异，这可能会影响健康状况、医疗资源获取等方面，低收入群体可能面临更多健康管理挑战。




图 4 基本情况分布图

如下图 5 是对生活方式特征进行了详细分析, 重点关注身体活动、水果消费、蔬菜消费以及重度饮酒情况。如图 5 (A) 中显示 73.3% 的受试者是经常进行锻炼的, 而 26.7% 很少进行锻炼, 大多数人群有规律的进行身体活动, 表明身体活动在样本中的普及率较高。图 5 (B) 和 (C) 中的果蔬食用情况可知水果和蔬菜的摄入比例较高, 表明该人群在饮食方面较为健康, 符合健康饮食的基本标准。水果和蔬菜富含膳食纤维、维生素和矿物质, 已被证明在血糖控制、减重及心血管健康方面具有积极作用。图 5 (D) 显示了重度饮酒情况, 93.9% 的受试者没有重度饮酒习惯, 仅有 6.1% 的受试者属于重度饮酒者, 说明绝大多数人群的饮酒频率处于较低水平。综上图 5 中的数据表明受试者普遍拥有较为健康的生活方式, 较高比例的人群参与身体活动, 水果和蔬菜摄入量较大, 且饮酒行为保持在较低水平。这些生活方式特征与糖尿病及其他慢性疾病的风险因素密切相关, 为后续的健康干预与糖尿病预防提供了宝贵的依据。




图 5 生活方式分析

如下图 6 本文对受试者的健康指标特征进行了详细分析，重点关注高血压、高胆固醇、总体健康状况以及医疗保障覆盖情况。图 5（A）显示在高血压的性别分布中，女性中有 56.6% 的受试者血压正常，而 43.4% 患有高血压；男性中，51.9% 的受试者血压正常，48.1% 患有高血压，男性在高血压的发病率上略高于女性；图 5（B）呈现了高胆固醇的性别分布，女性中 56.8% 的受试者胆固醇正常，43.2% 患有高胆固醇；男性中 54.6% 的受试者胆固醇正常，45.4% 患有高胆固醇。尽管整体差异较小，但男性的高胆固醇发病率仍高于女性。图 5（C）反映了总体健康状况，大多数受试者的健康状况为“好”或“一般”，其中 33.7% 的人评为“很好”，32.1% 评为“一般”。只有 19% 的受试者认为自己的健康程度为“差”。这一分布反映了样本普遍健康。图 5（D）展示了医疗保障的覆盖情况，94.6% 的受试者拥有医疗保险，5.4% 的受试者未享有医疗保障。尽管大部分受试者能够获得医疗保障，但仍有少数群体缺乏必要的健康保障。




图 6 健康指标分析

3.2 多变量分析

如下图 7 展示的是特征的相关系数热力图，通过颜色和数值展示不同特征之间的线性相关程度，红色代表正相关，蓝色代表负相关，颜色越深、数值越接近 ± 1 。在糖尿病二分类变量（`Diabetes_binary`）与其他特征之间的相关性分析中发现了部分关键的正相关和负相关关系。总体健康状况（`GenHlth`）与是否患糖尿病呈较强的正相关，表明自评健康较差的个体更可能患有糖尿病；此外，行动困难（`DiffWalk`）与糖尿病也呈正相关，这一结果反映了行动不便的个体在患糖尿病的风险上可能更高；高血压（`HighBP`）与糖尿病之间有显著的正相关关系，高血压是糖尿病的常见共病症；年龄（`Age`）与糖尿病也存在一定的正相关，这表明糖尿病在老年群体中更为常见。相反，收入（`Income`）与糖尿病呈弱负相关，表明高收入人群的糖尿病发病率较低。教育程度（`Education`）与糖尿病的负相关也显示教育水平较高的人群可能更加注重健康生活方式，从而降低了糖尿病的风险。在特征间的相关性分析中，高血压（`HighBP`）与高胆固醇（`HighChol`）的相关系数为 0.28，表明二者之间存在一定的共同风险因素。总体健康（`GenHlth`）

与生理健康（PhysHlth）的相关系数为 0.52，行动困难（DiffWalk）与生理健康（PhysHlth）的相关系数为 0.45，说明个体的自评健康状况、行动能力与实际的身体健康状况紧密相关。收入（Income）与教育程度（Education）呈中等强度的正相关（0.42），这一结果表明高收入群体往往受教育程度较高。可以发现特征之间并步存在显著的高度相关，所以不需要对特征进行多重共线性的处理。




图 7 热力图

在完成热力图分析后，对于具有一定相关性的特征进行多变量分析，多变量分析不仅能够揭示多个变量之间的复杂关联，并为后续的模型构建提供有力支持。如下图 8，图 8（A）展示了总体健康状况（1=“非常好”）与是否患糖尿病的关系，可以看出总体健康较差的个体患糖尿病的比例较高，而总体健康状况较好的个体中糖尿病患病率显著降低。图 8（B）显示在所有患有高血压的个体中，糖尿病的患病比例为 25.3%，而未患高血压的个体仅有 6.9%患糖尿病。图 8（C）展示了有行动困难的个体中，糖尿病的患病比例明显高于无行动困难的个体，行

动困难会导致锻炼频次减低，所以行动障碍与糖尿病之间存在明显的关联。图 8 (D) 反映了随着年龄的增加，糖尿病的患病比例呈现先上升后下降的趋势。尤其在 70-74 岁年龄组的糖尿病的患病率显著增加，表明年龄是糖尿病的重要风险因素。图 8 (E) 显示糖尿病患病群体的收入水平普遍较低，而非糖尿病群体的收入水平则较高。图 8 (F) 显示了 BMI 与是否患糖尿病的关系，非糖尿病组的 BMI 集中在较低区间，而糖尿病组的 BMI 不仅中位值高，数据离散范围也更偏向高 BMI 区域，进一步强化了“高 BMI 与糖尿病患病相关”的结论。




图 8 糖尿病风险因素的关键特征分析

如图 9 展示了 3 组特征的正相关关系，图 9 (A)展示了高血压与高胆固醇之间的关系，数据点集中在 4 个象限；其中，糖尿病患者更多分布在“有高血压+有胆固醇”的右上角象限，说明这两个风险因素共存时，糖尿病概率更高。其次则是在右下角象限出现的红色点较多，说明高血压是比高胆固醇更具有影响的因素。图 9 (B) 展示了总体健康与生理健康之间的关系，GenHlth 是 1-5 的等级变量（1=极好，5=差），随着总体健康变差，PhysHlth 的分布区间明显上升。图 9 (C) 表现了行动困难与生理健康之间的关系，在有行动困难的样本中 PhysHlth 天数显著高于无困难的样本。综上，风险因素越严重，健康问题越突出、糖尿病概率越高。




图 9 特征与因变量正相关

如下图 10 展示了特征与因变量的负相关关系，图 10（A）为小提琴图结合箱线图，展示不同收入水平下总体健康状况，随着收入等级升高，GenHlth 的分布中心显著向健康更好偏移，收入水平越高，个体自评总体健康状况越好，且高收入组的健康分布更集中。图 10（B）为均值±标准差折线图，呈现不同收入水平下，糖尿病与非糖尿病群体行动困难的均值变化，糖尿病群体与非糖尿病群体的 DiffWalk 均值均随收入升高而显著下降，同一收入水平下，糖尿病群体的 DiffWalk 均值始终高于非糖尿病群体。这一结果揭示了收入作为社会经济因素对健康结局的正向影响。




图 10 特征与因变量负相关

如下图 11 是多特征组合分析，图 11（A）为年龄类别与总体健康的关联气泡图，气泡大小代表对应组的样本数量。随年龄分组升高，健康状况变差，糖尿病群体的 GenHlth 等级普遍高于非糖尿病群体，且高年龄组中红色气泡占比增加。

图 11 的（B）和（C）展示了收入与教育程度的关联（分糖尿病状态），收入与教育程度呈强正相关，受教育程度越高，收入等级越高；且高教育、高收入群体的糖尿病风险显著更低。




图 11 多特征组合分析

如下图 12 采用桑基图对多维健康数据流向进行了可视化分析，旨在量化年龄、体重状况、代谢风险、总体健康状况与糖尿病结局五个层级变量之间的样本转移模式和相关性。图中线条的宽度直接反映了不同状态之间的样本频率，从而为评估条件概率和风险传递效应提供了直观的统计基础。

观察显示，年龄是体重分布的关键影响因素。青年组的主流样本流向为“体重正常”，而中年组则向“肥胖”和“超重”状态呈现显著的带宽增粗趋势，说明中年发福是该群体面临的主要健康挑战。在体重与代谢风险的关系上，揭示了强烈的正相关性：从“肥胖”节点流出的样本，绝大部分导向“双重高危”，“仅高血压”或“仅高血脂”等代谢异常状态，只有极少部分流向“代谢正常”。这与“体重正常”样本流向以“代谢正常”为主形成鲜明对比，直观展示了保持正常体重对维护代谢健康的显著保护作用。此外，老年组样本在“仅高血压”节点上占比较大，可能高血压风险在控制了体重因素后，仍具有独立于年龄的相关性。

流向为青年/中年到体重正常到代谢正常到健康：优，最后是无糖尿病。这条路径的连贯性强、宽度大，提示在疾病链条的早期进行干预和维持，对于保持终生健康状态至关重要。流向为中年/老年到肥胖/超重到双重高危到健康：差，最后是患糖尿病。该路径揭示了慢性病风险的累积效应。从“肥胖”和“超重”累积至“双重高危”的样本，最终大量汇入“健康：差”和“患糖尿病”终点。




图 12 糖尿病多因素流向桑基图

四、聚类分析

本研究进一步采用无监督学习方法对样本进行聚类分析，旨在从数据驱动的角度发现潜在的亚群结构，揭示不同健康风险模式与糖尿病患病状态之间的内在关联。通过对全部特征进行标准化处理后，使用 K-means 算法对个体在多维健康指标空间中的分布进行划分，以期识别出具有相似健康特征与风险因素的自然群体，为后续的精准确防与分层干预策略提供依据。

为了确定最佳的聚类数目，本研究采用轮廓系数、戴维森-堡丁指数（DBI）以及卡林斯基-哈拉巴斯指数（CHI）作为内部有效性指标进行评估。通过对比 K=2 与 K=3 的聚类结果,如下表 2 各项指标均显示,当 K=2 时,轮廓系数为 0.1810,显著高于 K=3 时的 0.0693,同时,K=2 时的 DBI 值为 2.6226,低于 K=3 时的 3.0250,较低的 DBI 值进一步证实了簇间差异的显著性。此外，CHI 值在 K=2 时达到 27014.58，远超 K=3 时的 20634.06，故 K=2 具有更优的聚类结构。

表 2 聚类指标对比

聚类数目 K	轮廓系数	DBI	CHI
2	0.1810	2.6226	27014.58
3	0.0693	3.0250	20634.06

通过采用 K-Means 算法对数据集进行无监督聚类，成功地将样本群体划分为两个具有显著不同特征的亚群：Cluster 0 和 Cluster 1。根据降维可视化图 12，可以观察到两个集群在特征空间中的分布模式，PCA 将数据投影到方差最大的两个维度上。图 13 (A) 中显示，Cluster 0 和 Cluster 1 在二维平面上存在一定的分离趋势，尤其是在主成分 1 轴上，但两个集群之间存在大面积的重叠区域。这表明在捕获最多数据方差的线性维度上，两个群体的界限是模糊的，其差异是复杂且多维的。由图 13 (B) 中可知 t-SNE 擅长保留数据的局部结构，能更清晰地揭示高维空间中的近邻关系。在 t-SNE 图中，两个集群的分布呈现出更强的聚集性。尽管两个颜色的点簇仍然有所交织，但同色点倾向于形成更紧密的“岛屿”，显示出 Cluster 0 和 Cluster 1 在数据结构上确实存在差异。




图 13 降维可视化图

下图 14 直接关联了无监督聚类结果与核心目标变量（是否患有糖尿病），在 Cluster 0 中，糖尿病患者占比仅为 9.5%，高达 90.5%的成员为非糖尿病患者。这清晰地表明 Cluster 0 代表了“健康/低风险群体”；而在 Cluster 1 中，糖尿病患者比例显著升高至 31.6%，远高于 Cluster 0。因此，Cluster 1 可以被定义为“亚

健康/高风险群体”。




图 14 各集群的糖尿病患病率

如下图 15 的雷达图直观地展示了两个集群在关键特征上的均值差异，描绘了清晰的用户画像。已知 Cluster 0 代表“健康/低风险群体”，由下图 15 可知该群体在高血压（HighBP）和高胆固醇（HighChol）方面的指标值较低，BMI 值也相对较低。他们表现出更高的体力活动水平（PhysActivity），且该群体相对更年轻，并且拥有更高的教育水平和收入水平。他们的总体健康状况（GenHlth）更好，表明他们自我感觉更健康。相反，Cluster 1 代表“亚健康/高风险群体”，由下图可知该群体的高血压、高胆固醇和 BMI 指标值均显著偏高，他们的体力活动水平明显较低该群体年龄偏大，且教育和收入水平均低于 Cluster 0。总体健康状况较差。

K-Means 聚类分析取得了非常成功的成果。它不仅在数据结构上实现了有效划分，更重要的是，划分出的两个集群具有清晰且截然不同的现实画像。




图 15 聚类特征画像雷达图

五、糖尿病分类预测模型构建

本文旨在利用机器学习技术，通过分析一系列易于获取的个人健康指标数据，构建一个精准、高效的预测模型。其本质上是一个二元分类问题，模型需要根据输入的特征，将个体准确地划分为“患有糖尿病”或“未患糖尿病”两个类别。通过这种方式，可以进行早期风险筛查，从而辅助个人和医疗机构及早识别高危人群，采取及时的预防措施或生活方式干预。

5.1 Logistic 模型

本文首先采用 Logistic 回归作为基准模型进行糖尿病预测。Logistic 回归是一种经典的线性分类算法，具有模型可解释性强、训练速度快的优点。因为数据存在严重的类别不平衡问题，非糖尿病患者有 19 万 2905 例，而糖尿病患者仅有 3 万 4394 例，占比约为 85% 比 15%。这可能会导致最后的分类预测会偏向占比更高的非糖尿病患者类别。故本文在模型中设置 `class_weight = 'balanced'` 参数，该参数会根据各类别样本数量的倒数自动调整权重，使模型在训练过程中对少数类给予更高的关注度。同时，采用 L2 正则化来防止模型过拟合，正则化强度参数 C 设为 1.0。在最后的在模型评估阶段，使用 5 折分层交叉验证在训练集上评估模型性能，以获得更稳健的性能估计。

表 3 Logistic 评价指标

评价指标	值
AUC	0.8106
召回率	0.7601
特异度	0.7060
准确率	0.7143
F1 分数	0.4487

如表 3 所示为 Logistic 回归模型在测试集上的评价指标结果，下图 16 展示了 ROC 曲线图。AUC 值为 0.8106，表明模型具有较好的整体区分能力，能够有效区分糖尿病患者与非糖尿病患者；召回率为 0.7601，意味着在所有真实的糖尿病患者中，模型成功识别出了其中的 76.01%，漏诊率为 23.99%；特异度为 0.7060，表示在所有健康个体中，约 70.60% 被正确识别为“非糖尿病”，假阳性率为 29.40%；

准确率为 0.7143，反映了模型整体的分类正确率；F1 分数为 0.4487，由于数据不平衡的影响，F1 分数相对较低，但在不平衡数据集中仍具有参考价值。

作为一种线性模型，Logistic 回归的优势在于其系数可直接解释为各特征对患病风险的影响程度，便于医学专家理解和验证。然而，其线性假设限制了模型捕捉特征间复杂非线性关系的能力。




图 16 Logistic-ROC 曲线图

5.2 随机森林模型

为进一步提升预测性能，本文采用随机森林算法构建糖尿病预测模型。随机森林是一种基于 Bagging 思想的集成学习方法，通过构建多棵决策树并综合其预测结果，能够有效降低过拟合风险，提高模型的泛化能力。在模型构建过程中，如下表 4，设置了以下关键超参数：

表 4 随机森林超参数

超参数	值
n_estimators	800
max_depth	12
min_samples_split	10
min_samples_leaf	5

max_features	sqrt
class_weight	balanced

同样采用 5 折分层交叉验证评估模型性能后，在全部训练数据上训练最终模型。如表 5 所示为随机森林模型在测试集上的评价指标结果。

表 5 随机森林评价指标

评价指标	值
AUC	0.8171
召回率	0.7531
特异度	0.7250
准确率	0.7293
F1 分数	0.4597

结合图表分析可得，AUC 值为 0.8171，相较于 Logistic 回归提升了 0.0065，表明集成学习方法在区分能力上有所改进；召回率为 0.7531，略低于 Logistic 回归的 0.7601，可能是由于随机森林在追求整体性能时对召回率有所权衡；特异度为 0.7250，较 Logistic 回归提升了 0.019，假阳性率降低至 27.50%，减少了健康人群被误判的情况；准确率为 0.7293，较 Logistic 回归提升了 0.015；F1 分数为 0.4597，较 Logistic 回归提升了 0.011，反映了精确率和召回率的综合改善。

随机森林的优势在于能够自动捕捉特征间的非线性关系和交互效应，同时通过集成多棵决策树降低了单一模型的方差。此外，该算法还能够输出特征重要性排序，为识别糖尿病的关键风险因素提供参考依据。




图 17 随机森林-ROC 曲线图

5.3 XGBoost 模型

最后采用强大的 XGBoost 算法构建一个机器学习模型来预测个体是否患有糖尿病。首先，数据存在严重的类别不平衡问题，为了找到 XGBoost 模型的最佳配置，本文采用了 Optuna 库进行超参数自动化优化，表 6 展示了各超参数的搜索空间设置，共涉及 10 个关键超参数，涵盖了模型复杂度控制、正则化、随机采样以及类别不平衡处理等多个维度。以期获得最佳的预测性能。在框架中设置 `scale_pos_weight` 参数，这个参数用于在损失函数中增加少数类样本的权重，从而有效缓解数据不平衡问题，让模型更加关注对少数类的正确预测。在每次试验，使用 5 折分层交叉验证在训练集上评估一组超参数的性能。交叉验证可以提供更稳健的性能估计，避免模型在特定数据划分上过拟合。Optuna 运行了 50 次试验，探索不同的超参数组合，并最终找到了在交叉验证中得到平均 AUC 得分最高的组合。最后使用 Optuna 找到的最佳超参数集，在全部训练数据上重新训练一个最终的 XGBoost 模型。

表 6 XGBoost 超参数搜索空间

超参数	搜索范围
<code>n_estimators</code>	[200, 1000]
<code>max_depth</code>	[4, 10]

learning_rate	[0.01, 0.2]
subsample	[0.6, 0.9]
colsample_bytree	[0.6, 0.9]
min_child_weight	[1, 20]
gamma	[0, 5]
reg_alpha	[1e-8, 10.0]
reg_lambda	[1e-8, 10.0]
scale_pos_weight	[5.04, 6.16]*

如上表 7 是测试集的评价指标结果，计算了准确率、特异度、召回率、F1 分数和 AUC 值，并生成了如下图 18 的 ROC 曲线图。具体可知 0.8201 的 AUC 值表明模型具有良好的区分能力；0.7677 的召回率代表着低漏诊率，它意味着在所有真实的糖尿病患者中，模型成功识别出了其中的 76.77%；72.08%的特异度意味着在所有健康的个体中，模型正确地将他们判断为“非糖尿病”，假阳性率为 0.2792，这意味着大约 27.92%的健康人会被模型错误地标记为“可能患有糖尿病”；但在疾病筛查中，假阴性（漏诊）的危害通常大于假阳性（误诊），因为漏诊可能延误治疗，导致不可逆的健康损害。

表 7 XGBoost 评价指标

评价指标	值
AUC	0.8201
召回率	0.7677
特异度	0.7208
准确率	0.7280
F1 分数	0.4633




图 18 XGBoost-ROC 曲线图

为全面评估不同机器学习算法在糖尿病预测任务中的表现，本文将 Logistic 回归、随机森林和 XGBoost 三种模型进行综合对比分析，结果汇总如表 8 所示。

表 8 三种模型评价指标对比

评价指标	Logistic 回归	随机森林	XGBoost
AUC	0.8106	0.8171	0.8201
召回率	0.7601	0.7531	0.7677
特异度	0.7060	0.7250	0.7208
准确率	0.7143	0.7293	0.7280
F1 分数	0.4487	0.4597	0.4633

从 AUC 值来看，三种模型的排序为：XGBoost> 随机森林> Logistic 回归。XGBoost 相较于基准模型 Logistic 回归提升了 0.0095，表明梯度提升集成方法在整体区分能力上具有明显优势。三种模型的 AUC 值均超过 0.8，说明在糖尿病预测任务中都具备良好的分类性能。在疾病筛查场景中，召回率是最关键的指标之一，因为漏诊（假阴性）可能导致患者错过最佳治疗时机。从召回率来看，XGBoost> Logistic 回归> 随机森林。XGBoost 模型能够识别出 76.77%的糖尿病患者，漏诊率仅为 23.23%，在三种模型中表现最优。特异度反映了模型正确识别健康个体的能力。从特异度来看，随机森林> XGBoost> Logistic 回归。随机森

林在减少假阳性方面表现最佳。然而，在医学筛查应用中，考虑到漏诊的危害通常大于误诊，因此召回率的优先级应高于特异度。F1 分数综合考虑了精确率和召回率的平衡。从 F1 分数来看，XGBoost> 随机森林> Logistic 回归。尽管受数据不平衡影响 F1 分数整体偏低，但 XGBoost 仍展现出最佳的综合性能。

综合以上分析，XGBoost 模型在糖尿病预测任务中表现最优。

六、基于 SHAP 的模型可解释性分析

尽管先前构建的 XGBoost 模型在糖尿病预测任务上展现了优异的分类性能，但其内在的复杂性和集成树结构使其本质上成为一个“黑箱”模型。在医疗诊断等高风险决策领域，仅仅获得高精度的预测结果是远远不够的；理解模型“为何”做出特定预测，即模型的可解释性，对于建立临床信任、验证模型决策逻辑的可靠性、以及发掘潜在的生物学或行为学关联至关重要。为了打开这一“黑箱”，本文引入了基于博弈论的 SHAP 框架进行事后可解释性分析。SHAP 是一种先进的、模型无关的解释方法，它通过计算每个特征对单次预测的贡献度，能够提供坚实理论基础支持下的全局可解释性和局部可解释性。全局层面，我们可以识别出对整体模型影响最大的关键特征；局部层面，我们可以深入剖析对于每一个具体样本，模型是如何权衡各项指标最终得出其患病风险预测的。

如下图 19 的 SHAP 摘要图提供了模型决策的宏观视角，揭示了哪些特征对预测结果的贡献最大，以及这些特征如何影响预测方向。最重要的五个预测因子为 GenHlth（总体健康状况）、Age（年龄）、BMI（身体质量指数）、HighBP（高血压）、HighChol（高胆固醇）。GenHlth 是最具影响力的特征，图中的点颜色显示，代表健康状况良好的个体，其 SHAP 值主要分布在负半轴，显著降低了糖尿病的预测风险。相反，代表健康状况差的个体，其 SHAP 值集中在正半轴，极大地推高了患病风险。Age 与 BMI 这两个特征表现出相似的正相关模式。年龄越大或 BMI 越高，对应的 SHAP 值也趋向于正值，增加了糖尿病风险。反之，年龄较小或 BMI 较低的个体，其 SHAP 值为负，也就降低了患糖尿病的风险。HighBP 和 HighChol 清晰地显示出两个聚类，即无高血压/高胆固醇的 SHAP 值均为负，降低了风险；而患有高血压/高胆固醇的 SHAP 值均为正，增加了风险。这证明模型成功捕捉到了这些共病对糖尿病风险的直接推动作用。对于其他特征，

男性患糖尿病的风险也会比女性高，无 CholCheck（胆固醇检查史）的个体也会显著减低其患糖尿病的风险，HvyAlcoholConsump（大量饮酒）中蓝点主要在正半轴，红点主要在负半轴，说明减少饮酒则会显著降低风险。




图 19 SHAP 摘要图

为了深入探究特征如何具体影响模型输出，并观察它们之间的交互作用，所有特征值均已呈现标准化处理后的分布。图 20 展示了关键特征依赖性与交互效应分析，如图 20（A）的 GenHlth 与 SHAP 值之间存在极强的正向单调相关性。随着自评健康状况变差图，其 SHAP 值呈现显著的阶梯状上升，从约-0.2 跃升至 +0.2。颜色变量为 CholCheck，在每一个固定的 GenHlth 水平上，数据点在垂直方向上的离散度反映了 CholCheck 的影响。这在统计上表明在控制了健康状况后，是否进行胆固醇检查对糖尿病风险的边际调节作用相对较弱，GenHlth 本身的主效应占据主导地位。图 20（B）统计趋势显示，Age 与 SHAP 值之间存在显著的近线性正相关。随着标准化年龄值的增加，SHAP 值从-0.3 稳步上升至 0.1 以上。颜色变量为 Sex，在相同的年龄切片下，观察垂直方向的点的分布，可以发现在

某些年龄段若出现颜色分层，但整体来看，年龄的主效应独立且显著。图 20 (C) 展示了 BMI 与 SHAP 值的关系呈现出显著的非线性特征，具体表现为“对数增长”形态。在低 BMI 区间，随着 BMI 增加，SHAP 值急剧上升，说明在正常体重到超重初期，体重增加对糖尿病风险的边际贡献极大。在高 BMI 区间，曲线趋于平缓甚至略有波动，呈现出“边际效应递减”的统计特征。颜色变量为 Age，在 BMI 较高的区域，红色点明显分布在蓝色点的上方。这在统计上揭示了“高 BMI”与“高龄”同时存在时，其产生的糖尿病风险高于两者单独作用的简单加和。图 20 (D) 的左侧集群中 SHAP 值全部为负，而右侧集群的 SHAP 值全部为正，说明模型将“是否患有高血压”作为一个明确的风险开关。对于有“有高血压”的群体，颜色的分布显示，年龄越大 SHAP 值越高。说明对于已经患有高血压的人来说，年龄的增长会进一步放大其糖尿病风险。




图 20 关键特征依赖性与交互效应分析

在对模型的全局行为进行宏观理解后，利用 SHAP 瀑布图对测试集中的三个代表性个体——“高风险患者”、“低风险患者”与“边界案例”，进行局部可解释性分析。此分析旨在揭示模型对于每一个独立预测的精细决策逻辑。

如图 21，GenHlth（总体健康状况）是最强的单一风险驱动因素，贡献了 0.12 的 SHAP 值。Age 与 BMI 均处于较高水平，各自贡献了 0.07 和 0.06 的 SHAP 值，是并列第二的风险因素。高胆固醇（HighChol）、高血压（HighBP）和心脏病（HeartDiseaseorAttack）均显著且独立地增加了预测风险。




图 21 高风险患者 SHAP 瀑布图

如图 22，揭示了模型如何识别一个非常健康的个体，并将其风险评估降至接近零。但与高风险患者相反，所有关键特征均提供了负向的 SHAP 值，共同将风险从基线大幅拉低，最终预测概率趋近于 0。CholCheck（胆固醇检查）是最强的单一保护性因素，贡献了-0.12 的 SHAP 值；Age（年龄）提供了-0.1 的显著风险削减；GenHlth 与 BMI 分别贡献了-0.08 和-0.05 的保护性 SHAP 值。该个体的健康画像是多重保护因素的综合体现，模型将良好的健康状况、正常的生理指标、无关键共病以及积极的健康行为识别为强烈的负向信号，些因素的累积效应有效地抵消了群体的平均风险。




图 22 低风险患者 SHAP 瀑布图

如下图 23 展示了模型的决策权衡能力，分析表明该样本呈现出典型的风险对抗特征，HighBP（高血压）和 HighChol（高胆固醇）的 SHAP 值分别为+0.08 和+0.07，作为显著的代谢风险因子推高了患病概率，但该负向影响被 BMI（SHAP=-0.09）的强保护效应所大幅抵消，其权重甚至超过了单一高血压特征的贡献。此外，相对年轻的年龄与医疗费用无障碍进一步起到了风险抑制作用。这一量化权衡过程证明，模型并非线性地依赖单一高危指标，而是能够综合处理特征间的异质性交互，通过体重与代谢指标的博弈，精准量化个体在混合临床特征下的最终糖尿病风险。




图 23 边界案例 SHAP 瀑布图

七、总结与展望

1.总结

本研究基于 CDC 大规模真实世界数据，深入探讨了多维度健康特征与糖尿病发病风险之间的复杂关联，并通过构建先进的机器学习模型与可解释性框架，实现并通过了以下核心研究成果的验证：

通过探索性数据分析与 K-Means 聚类分析，本研究成功揭示了人群中存在的自然风险分层结构。研究发现，高血压、高胆固醇、高 BMI 以及较差的自评健康状况是糖尿病患者群体的核心特征画像。聚类结果明确将人群划分为“健康/低风险群体”与“亚健康/高风险群体”，其中“亚健康/高风险群体”的糖尿病患病率是“健康/低风险群体”的三倍以上。这一发现验证了基于生活方式与临床病史的非侵入性指标在人群风险分层中的有效性，为公共卫生领域的精准防控提供了分群依据。

针对医疗数据普遍存在的类别不平衡问题，本研究系统比较了 Logistic 回归、随机森林和 XGBoost 三种机器学习算法在糖尿病风险预测任务中的性能表现。综合评估结果表明，采用 Optuna 超参数优化策略的 XGBoost 模型在整体区分能力（AUC=0.8182）、漏诊控制能力（召回率=0.7776）以及综合分类性能（F1 分数）三个维度上均优于 Logistic 回归和随机森林模型，展现出最佳的预测效果。在疾病筛查场景中，XGBoost 模型的高召回率意味着能够有效识别出绝大多数潜在的糖尿病患者，最大限度降低漏诊带来的健康风险。该结果充分证明，无需依赖昂贵的实验室生化检测，仅凭人口统计学与基础健康问卷数据，结合先进的梯度提升集成学习方法，即可实现较高精度的糖尿病早期风险筛查。

本研究的创新点在于引入 SHAP 框架打破了复杂集成模型的“黑箱”壁垒，建立了临床信任。确认了总体健康自评、年龄、BMI 以及基础共病（高血压、高胆固醇）是驱动模型决策的最关键因素。这与现有的医学病理认知高度一致，验证了模型逻辑的科学性。也揭示了特征间的非线性交互作用，高龄与高 BMI 的叠加效应会呈倍数放大患病风险，这为理解复杂病因提供了量化视角。通过瀑布图对个体样本的精准剖析，展示了模型如何权衡“保护性因素”与“风险性因素”。这种细粒度的解释能力使得该模型不仅能告诉患者“风险有多高”，还能

指出“为什么风险高”。

综上所述，本研究建立的“多维特征+XGBoost+SHAP”综合分析框架，不仅具有较高的预测效能，更具备极强的临床解释性。它为糖尿病的早期预警提供了一种低成本、易推广的解决方案，有助于推动从“被动治疗”向“主动预防”的健康管理模式转变，具有重要的公共卫生应用价值。

2.展望

尽管本研究取得了一定的成果，但仍存在若干局限性，未来可从以下几个方面进行深入探索与改进：

本研究主要采用传统机器学习方法，未来可探索深度学习技术在糖尿病预测中的应用潜力。例如，利用 TabNet、NODE 等面向表格数据的深度学习架构，或采用 Transformer 结构捕捉特征间的复杂依赖关系。在类别不平衡处理方面，除现有的代价敏感学习策略外，还可探索 SMOTE、ADASYN 等过采样技术或基于生成对抗网络（GAN）的数据增强方法，以优化少数类的识别能力。

本研究采用 SHAP 方法实现了模型的事后解释，未来可进一步探索内在可解释模型与复杂模型的性能对比，寻求预测精度与可解释性之间的最优平衡。同时，可结合因果推断方法，从关联分析深入到因果机制探索，为临床干预措施的制定提供更具指导意义的证据支撑。

在应用方面，未来可将模型封装为轻量级风险评估工具，开发面向基层医疗机构的辅助诊断系统或面向公众的健康管理应用。通过前瞻性临床验证研究，评估模型在真实医疗场景中的实际效用，推动研究成果从理论走向实践。

参考文献

- [1] 张占林,孙勇,妥小青,等.随机森林算法对体检人群糖尿病患病风险的预测价值研究[J].中国全科医学,2019,22(09):1021-1026.
- [2] 覃伟,高敏,沈莹,等.基于机器学习算法的2型糖尿病患者3个月血糖预测[J].中华疾病控制杂志,2019,23(11):1313-1317.
- [3] Hasan M K, Alam M A, Das D, et al. Diabetes prediction using ensembling of different machine learning classifiers[J]. IEEE Access, 2020, 8: 76516-76531.
- [4] Krawczyk B. Learning from imbalanced data: open challenges and future directions[J]. Progress in artificial intelligence, 2016, 5(4): 221-232.
- [5] Akiba T, Sano S, Yanase T, et al. Optuna: A next-generation hyperparameter optimization framework[C]//Proceedings of the 25th ACM SIGKDD international conference on knowledge discovery & data mining. 2019: 2623-2631.
- [6] Lundberg S M, Lee S I. A unified approach to interpreting model predictions[J]. Advances in neural information processing systems, 2017, 30.

数据集来源: <https://github.com/anaskanafani/diabetes-detection>